量化交易入门指南：第12天 – 价值因子与动量因子的本质逻辑

原创 逻辑与流 逻辑与流 2025年9月9日 00:16 北京 6人

学习时间：60分钟

> 本文为量化交易学习系列第12天内容，深度剖析低市盈率（价值因子）和动量因子的长期有效性、背后逻辑、实证研究与实战应用，帮助你理解现代多因子投资的核心。

一、为什么低市盈率（PE）的股票长期表现更好？——价值因子的本质逻辑

1. 从实证数据来看：价值因子是有效的

- 学术研究（如 Fama-French 三因子模型）和实践经验都发现：
  - 低 PE（或低 PB、低EV/EBITDA） 的股票，在长期内平均收益率高于高估值股票。
  - 这构成了"价值因子"（Value Factor）策略的核心：买入低估值、卖出高估值的股票组合，获取超额收益。

> **但关键问题是——为什么会这样?**

2. 三种主流解释

1 风险补偿理论（Risk-Based View）

- 代表人：Fama-French
- "价值股"其实风险更高，所以投资者需要获得更高的预期收益作为补偿。
- 低 PE 的股票通常处于困境、行业周期底部、或财务恶化状态，未来不确定性大，市场给出低估值。
- 长期来看，这些股票平均会给出更高的收益，作为承担更高风险的补偿。

举例：煤炭股在行业周期底部时，PE 可能只有 3~5 倍，但如果周期反转，利润暴涨，股价上涨可翻倍。

2 行为偏差理论（Behavioral View）

- 代表人：Lakonishok, Shleifer, Vishny 等
- 市场存在系统性错误定价，投资者的"行为偏差"造成了价值股被低估。
- 投资者倾向于追捧"故事股"、成长股，低 PE 的股票往往"不性感"，被市场忽视，导致低估。
- 聪明的价值投资者通过"逆向操作"获取超额收益。

举例：很多人喜欢买新能源、科技、AI，但不屑于钢铁、水泥、银行等"低 PE 候选"，造成定价偏差。

3 坏消息过度反应 + 坏消息均值回归

- 当公司出现坏消息（盈利下滑、丑闻等）时，PE 会很低，投资者往往反应过度，导致价格过度下跌。
- 但很多公司经营稳健，有一定的恢复力，一旦恢复盈利，估值回升，股价上涨。

举例：某公司今年利润断崖式下跌，PE 变得很低，但如果只是暂时因素（如疫情、原材料暴涨），明年恢复盈利就可能股价翻倍。

3. 现实中你该怎么用价值因子?

- 单独看 PE 不够，要结合多维因子选股：
  - 综合使用 PE、PB、EV/EBITDA、股息率等构建"价值得分"；
  - 排除掉"伪价值股"（坏账、高负债、僵尸企业）；
  - 与"质量因子"搭配（选低估 + 高质量）；
  - 长期持有 + 分散组合 → 获得更稳健的超额收益。

4. 小结：价值因子的三大解释

理论视角	解释为什么低 PE 股票表现更好
风险补偿理论	价值股风险更高，收益也更高（是应得的）
行为偏差理论	市场错误定价 + 投资者偏好成长，低估价值股
情绪均值回归	坏消息后股价过度反应，后续均值回归反弹

> 这些理论可以互补解释低 PE 有效性的现象。

二、动量因子（Momentum Factor）：强者恒强的市场逻辑

1. 动量因子的基本定义

- 动量因子：过去表现好的股票未来一段时间内往往还会继续上涨，反之亦然。
- 常见定义：过去 3~12个月的收益率（常用过去12个月剔除最近1个月）；选取收益率排名靠前的一组股票（如前20%）构建"动量组合"。
- 实证研究发现：无论在美股、A股、欧洲、日本等市场，动量因子都显著存在，是多因子模型（如 Carhart 四因子模型）中的核心因子之一。

2. 为什么动量有效？（动量因子的本质逻辑）

1 行为金融学解释（最主流）

- 动量是市场参与者的非理性行为导致的价格惯性。

- 主要包括两类心理偏差：
  - **信息反应不足（Underreaction）**：投资者对利好消息反应缓慢，价格会缓慢上涨一段时间，形成"上涨的惯性"。
  - **羊群效应（Herding）与趋势跟随**：投资者喜欢追涨杀跌，技术派交易员根据趋势建仓，趋势形成后吸引更多人跟进，趋势被自我强化。

2 风险补偿理论（较弱的解释）

- 动量股票可能存在某种未被观测到的风险敞口，长期收益高是对特定风险的补偿。
- 但这种解释经常难以成立，因为动量组合的夏普比率很高，波动率不高。

3 市场结构机制（交易摩擦 + 投资限制）

- 某些大机构因合规限制、持仓限制、再平衡机制无法立刻调整，信息影响在价格中"延迟显现"，造成动量效应。

3. 动量策略如何构建?

- 典型动量选股流程：
  1. 对所有股票计算过去12个月收益率（剔除最近1个月）；
  2. 按收益率从高到低排序，选前20%股票为"高动量组合"；
  3. 每月或每季度进行再平衡；
  4. 对组合进行等权/市值权重投资；
- 动量还可以分为：
  - **绝对动量**：某资产自己过去涨 → 未来可能还涨；
  - **相对动量**：资产A涨得比资产B多 → 未来更可能继续强势。

4. 动量策略的风险与陷阱

风险	说明
反转效应	短期动量可能遭遇突发事件而迅速反转
回撤较大	动量策略在"市场风格突变"时会遭遇集体性失效
高换手、高交易成本	频繁调仓造成滑点和交易费用
与价值因子冲突	高动量股票往往估值也高，和价值因子"天然对立"

5. 动量因子的现实应用

- AQR、Two Sigma、Renaissance 等量化基金，都大量使用动量因子，但通常会：
  - 将动量因子与价值、质量、波动率等多因子结合；
  - 优化组合风险、提升稳定性；

- 控制换手率、降低交易成本。

6. 小结：动量因子的核心特性

特性	动量因子
定义	过去表现好的股票未来更容易继续表现好
理论解释	投资者行为偏差 + 信息反应延迟
策略方向	顺势而为、买强卖弱
风险	短期反转、高换手、风格切换回撤
应用方式	常与其他因子组合构建稳健策略

三、补充：PCA主成分分析的详细计算过程

在上一篇文章中，我们介绍了主成分分析（PCA）作为多因子降维的重要工具，但由于篇幅限制，没有给出详细的计算过程。今天我们来补充这部分内容，帮助大家更好地理解PCA的数学原理和实际应用。

1. PCA基本概念回顾

主成分分析（Principal Component Analysis, PCA）是一种统计降维技术，其核心思想是：

- 将多个相关的变量（因子）转换为少数几个不相关的主成分
- 每个主成分都是原始变量的线性组合
- 主成分按照解释方差的大小排序，第一个主成分解释最多的方差

在量化投资中的应用价值：

- 解决因子冗余问题：PE、PB、EV/EBITDA等估值因子高度相关
- 降维简化模型：从20+个原始因子提取3-5个主成分
- 识别独立风险源：避免虚假分散化，构建更稳健的投资组合

2. PCA详细计算过程：4只股票的3因子分析

让我们通过一个具体的例子来详细讲解PCA的每一步计算。假设我们有4只股票，每只股票有3个因子暴露：市盈率（PE）、净资产收益率（ROE）和动量因子（Momentum）。

第一步：原始数据准备

股票	PE (X_1)	ROE (X_2) %	Momentum (X_3)
股票A	10	15	0.5
股票B	12	20	0.7

股票	PE（ ）	ROE（ ）%	Momentum（ ）
股票C	15	10	-0.2
股票D	20	12	0.1

目标：将这三个相关性较高的因子 (X_1, X_2, X_3) 降维融合成1个或2个不相关的综合因子 (PC_1, PC_2)。

第二步：数据标准化

由于三个因子的量纲和尺度完全不同（PE是倍数，ROE是百分比，Momentum是收益率），必须进行标准化。

公式：

$$Z = \frac{x - \mu}{\sigma}$$

其中 μ是均值，σ是标准差。

计算各因子的均值和标准差：

因子	μ (均值)	σ (标准差)
PE (X_1)	(10+12+15+20)/4 = 14.25	$\sqrt{\frac{(10-14.25)^2+...+(20-14.25)^2}{4}} \approx 4.03$
ROE (X_2)	(15+20+10+12)/4 = 14.25	$\sqrt{\frac{(15-14.25)^2+...+(12-14.25)^2}{4}} \approx 4.03$
Momentum (X_3)	(0.5+0.7-0.2+0.1)/4 = 0.275	$\sqrt{\frac{(0.5-0.275)^2+...+(0.1-0.275)^2}{4}} \approx 0.35$

标准化后的数据矩阵 Z：

例如，股票A的PE标准化：

$$Z_{A1} = \frac{10 - 14.25}{4.03} \approx -1.055$$

以此类推，我们得到标准化后的矩阵 Z：

股票	Z_1 (PE)	Z_2 (ROE)	Z_3 (Momentum)
股票A	-1.055	0.186	0.643
股票B	-0.558	1.427	1.214
股票C	0.186	-1.055	-1.357
股票D	1.427	-0.558	-0.500

第三步：计算协方差矩阵

对于标准化后的数据，其协方差矩阵 C 实际上就是相关系数矩阵。计算公式为：

$$Cov_{ij} = \frac{1}{n-1}\sum_{k=1}^{n}(Z_{ki} - \bar{Z_i})(Z_{kj} - \bar{Z_j})$$

因为数据已经标准化，均值为0，所以公式简化为：

$$Cov_{ij} = \frac{1}{n-1}\sum_{k=1}^{n}Z_{ki}Z_{kj}$$

其中 $n = 4$（样本数）。

计算过程示例：

- Cov_{11}**(PE vs PE):**

$$\frac{1}{3}[(-1.055)^2 + (-0.558)^2 + (0.186)^2 + (1.427)^2] \approx \frac{1}{3}(1.113 + 0.311 + 0.035 + 2.036) \approx 1.165$$

- Cov_{12}**(PE vs ROE):**

$$\frac{1}{3}[(-1.055)(0.186) + (-0.558)(1.427) + (0.186)(-1.055) + (1.427)(-0.558)] \approx -0.661$$

- Cov_{13}**(PE vs Momentum):**

$$\frac{1}{3}[(-1.055)(0.643) + (-0.558)(1.214) + (0.186)(-1.357) + (1.427)(-0.500)] \approx -0.774$$

最终协方差矩阵 C：

$$C = \begin{bmatrix} 1.165 & -0.661 & -0.774 \\ -0.661 & 1.165 & 0.607 \\ -0.774 & 0.607 & 1.165 \end{bmatrix}$$

第四步：计算特征值和特征向量

我们需要解方程：$(C - \lambda I)\vec{v} = 0$，其中 λ是特征值，$\vec{v}$是特征向量。

特征方程：$det(C - \lambda I) = 0$

$$det\begin{bmatrix} 1.165 - \lambda & -0.661 & -0.774 \\ -0.661 & 1.165 - \lambda & 0.607 \\ -0.774 & 0.607 & 1.165 - \lambda \end{bmatrix} = 0$$

计算这个3×3矩阵的行列式（过程略，可通过SVD分解或使用计算器），我们得到三个特征值：

$$\lambda_1 \approx 2.514$$

$$\lambda_2 \approx 1.231$$

$$\lambda_3 \approx 0.750$$

按大小排序： $\lambda_1 > \lambda_2 > \lambda_3$

将每个特征值 λ代入方程 $(C - \lambda I)\vec{v} = 0$，求解向量 $\vec{v}$。

a) 对于 $\lambda_1 \approx 2.514$：

解方程组：

$$(1.165 - 2.514)v_1 - 0.661v_2 - 0.774v_3 = 0$$

$$-0.661v_1 + (1.165 - 2.514)v_2 + 0.607v_3 = 0$$

$$-0.774v_1 + 0.607v_2 + (1.165 - 2.514)v_3 = 0$$

化简为：

$$-1.349v_1 - 0.661v_2 - 0.774v_3 = 0$$

$$-0.661v_1 - 1.349v_2 + 0.607v_3 = 0$$

$$-0.774v_1 + 0.607v_2 - 1.349v_3 = 0$$

令 $v_1 = 1$，从前两个方程可以解出 $v_2 \approx -0.705$, $v_3 \approx -0.950$（过程略）。

得到向量 $\vec{v_1} = [1, -0.705, -0.950]^T$。

单位化（使其模长为1）：

$$||\vec{v_1}|| \approx \sqrt{1^2 + (-0.705)^2 + (-0.950)^2} \approx \sqrt{1 + 0.497 + 0.903} \approx \sqrt{2.4} \approx 1.549$$

单位化后的特征向量：

$$\vec{v_1} = [1/1.549, -0.705/1.549, -0.950/1.549]^T \approx [0.645, -0.455, -0.613]^T$$

b) 对于 $\lambda_2 \approx 1.231$：

同样方法，解得单位化后的特征向量约为：

$$\vec{v_2} \approx [-0.583, -0.735, 0.347]^T$$

c) 对于 $\lambda_3 \approx 0.750$：

同样方法，解得单位化后的特征向量约为：

$$\vec{v_3} \approx [0.495, -0.503, -0.709]^T$$

对应的单位化特征向量：

$$\vec{v_1} \approx [0.645, -0.455, -0.613]^T$$

$$\vec{v_2} \approx [-0.583, -0.735, 0.347]^T$$

$$\vec{v_3} \approx [0.495, -0.503, -0.709]^T$$

第五步：主成分解释与选择

方差解释率计算：

总方差 = $\lambda_1 + \lambda_2 + \lambda_3 = 2.514 + 1.231 + 0.750 = 4.495$

- PC1解释方差比例：$\frac{2.514}{4.495} \approx 55.9\%$
- PC2解释方差比例：$\frac{1.231}{4.495} \approx 27.4\%$
- PC3解释方差比例：$\frac{0.750}{4.495} \approx 16.7\%$

前两个主成分（PC1 + PC2）共解释了约 83.3% 的方差，因此我们可以选择降维到2维。

主成分的经济含义解释：

第一主成分 (PC1)： $\vec{v_1} = [0.645, -0.455, -0.613]$

- PE (0.645) 有很高的正载荷
- ROE (-0.455) 和 Momentum (-0.613) 有较高的负载荷

解释：这个主成分代表了 "高估值、低质量、负动量" vs "低估值、高质量、正动量" 的风格暴露。PC1得分高的股票是"高估值、低质量、负动量"的股票。

第二主成分 (PC2)： $\vec{v_2} = [-0.583, -0.735, 0.347]$

- ROE (-0.735) 和 PE (-0.583) 有很高的负载荷
- Momentum (0.347) 有正载荷

解释：这个主成分代表了 "低估值、高质量、正动量" vs "高估值、低质量、负动量"。PC2得分高的股票是"低估值、高质量、正动量"的优质股票。

第六步：计算主成分得分

将标准化后的原始数据 Z 投影到选定的主成分方向上。

投影矩阵 W：

$$W = \begin{bmatrix} 0.645 & -0.583 \\ -0.455 & -0.735 \\ -0.613 & 0.347 \end{bmatrix}$$

主成分得分矩阵 Y = Z ·W

计算股票A的得分：

PC1得分：

$$Y_{A1} = (Z_{A1}, Z_{A2}, Z_{A3}) \cdot (v_{11}, v_{21}, v_{31})^T = (-1.055 \times 0.645) + (0.186 \times -0.455) + (0.643 \times -0.613) \approx -0.680 - 0.085 - 0.394 \approx -1.159$$

PC2得分：

$$Y_{A2} = (Z_{A1}, Z_{A2}, Z_{A3}) \cdot (v_{12}, v_{22}, v_{32})^T = (-1.055 \times -0.583) + (0.186 \times -0.735) + (0.643 \times 0.347) \approx 0.615 - 0.137 + 0.223 \approx 0.701$$

同理计算所有股票，得到最终的2维主成分得分：

股票	PC1 Score	PC2 Score
股票A	-1.159	0.701
股票B	-1.343	1.405
股票C	1.589	-0.469
股票D	0.913	-1.637

投资含义解读：

- **股票B**：PC2得分最高(1.405)，代表"低估值、高质量、正动量"的优质股票
- **股票D**：PC2得分最低(-1.637)，代表"高估值、低质量、负动量"的股票
- **股票C**：PC1得分最高(1.589)，代表"高估值、低质量、负动量"风格
- **股票A**：PC1得分最低(-1.159)，代表"低估值、高质量、正动量"风格

3. PCA在量化投资中的实际应用价值

通过这个详细的PCA计算过程，我们可以看到：

1. **因子降维**：将3个相关因子压缩为2个独立的主成分，保留了83.3%的信息
2. **风险识别**：PC1代表"估值-质量-动量"综合风格，PC2代表"优质股票"特征
3. **投资决策**：股票B在PC2上得分最高，是典型的"低估值、高质量、正动量"优质股票
4. **模型简化**：从复杂的多因子分析简化为二维主成分分析

实际投资中的应用场景：

- **多因子选股**：从20+个原始因子中提取3-5个主成分进行选股
- **风险模型**：构建基于主成分的风险模型，更准确地估计投资组合风险
- **风格轮动**：基于主成分得分进行风格轮动策略
- **因子择时**：识别不同市场环境下主成分的有效性变化

总结

现在，你可以在二维平面上以PC1和PC2为轴，将4只股票绘制出来。股票B在PC2上得分最高，代表它是"低估值、高质量、正动量"的典型。股票D在PC2上得分最低，代表其风格相反。这为投资组合的构建和风格分析提供了极其有价值的信息。

通过Python代码实现，读者可以：

1. 验证手工计算的准确性
2. 理解每个步骤的具体实现
3. 可视化PCA的结果
4. 在实际项目中应用这些方法

5. 小结：价值因子、动量因子与PCA的完美结合

通过今天的学习，我们不仅深入理解了价值因子和动量因子的本质逻辑，还通过详细的PCA计算过程，掌握了多因子分析的核心工具。

分析层次	价值因子	动量因子	PCA主成分分析
理论基础	风险补偿/行为偏差	信息反应不足/羊群效应	线性代数/统计降维
应用目标	识别低估股票	捕捉趋势延续	多因子降维融合
投资策略	逆向投资	趋势跟随	综合因子投资
风险特征	长期均值回归	短期反转风险	系统性风险识别

这三个工具的结合，为构建稳健的多因子投资策略奠定了坚实基础。下一讲我们将进入"因子组合与风格轮动"的世界，敬请期待！

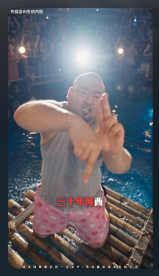
量化交易入门指南 · 目录 ≡

< 上一篇
量化交易入门指南：第11天 – 多因子选股模型（Factor Investing）

下一篇 >
量化交易入门指南：第13天 – 因子有效性评估：IC信息系数与IR信息比率的完整解析

阅读 305

广告



2026年超火爆的休闲小游戏，休闲又解压！

点击了解更多 ›

2026年超火爆的休闲小游戏，休闲又解压！

疯狂末日小游戏

立即试玩