量化交易入门指南：第23天 – 多期分层回测 & 多空组合

原创 逻辑与流 逻辑与流 2025年9月25日 00:56 北京 3人

本文深入探讨了量化因子研究中的多期分层回测方法，从单期横截面回测扩展到多期时间序列回测。文章详细介绍了IC时间序列分析、分层回测、滚动统计等核心概念，通过具体的手算示例和Python代码实现，帮助读者掌握因子多期验证的完整流程。同时深入讲解了多空组合的构建原理和评估方法，为量化因子研究提供实用的技术指导。

学习时间

- **理论学习**: 20分钟
- **代码实践**: 25分钟
- **思考总结**: 10分钟
- **总计**: 55分钟

一、单期 vs 多期回测

在之前的因子研究中，我们大多只做了**单期横截面回测**：

- 当期因子值 → 下一期收益
- 用 IC/分组回测来判断因子有效性

但是实盘需要更稳健的检验，所以我们要做**多期回测**：

- 连续滚动测试（跨多个时期）
- 看因子在长期下是否稳定有效

1 为什么称作「横截面」？

横截面（Cross-section）在统计学/计量经济学里，指的是**同一时间点下，不同个体的数据集合**。

- **横截面数据**：同一个时点，不同股票的因子值
- **例子**：2023年1月末，沪深300里所有股票的 PE、ROE、动量等
- **时间序列数据**：同一只股票，在不同时间上的数据
- **例子**：平安银行（000001）从 2015–2023 年的 ROE 变化

我们在因子检验里做的，就是一个**横截面回归/相关分析**：

- 拿某一期（比如 1月末）所有股票的因子值（横截面）
- 对比它们在**下一期收益**上的差异

所以称为**横截面回测/ 横截面检验**。

2 为什么用「1月末的因子」去预测「2月的收益」？

这就是因子研究的基本逻辑：

- **因子值**= 预测信号，**未来收益**= 被预测对象
- **因子（预测变量）**：我们能观测的，比如 1月末的 PE、ROE、动量
- **未来收益（被解释变量）**：我们想预测的，比如 2月的股票涨跌

举例

假设我们要研究「低 PE 因子」：

- 1月末：计算所有股票的 PE 值
- 根据这些 PE 值排序，分成高/低组
- 看 2月的实际收益表现：是不是低 PE 组（价值股）平均收益更高？

如果成立 → 说明这个因子有预测力。

3 为什么不是用「1月的收益」来验证 1月末的因子？

因为因子要发挥作用，必须**先观测到因子，再预测未来的回报**。

如果你用 1月的因子预测 1月的收益，那就会**偷看未来（look-ahead bias）**，失去了预测意义。

正确逻辑：

- **因子值时点**：月末、季末、财报发布日等（当下已知）
- **收益检验窗口**：下一期（月、季度），确保因子先于收益发生

4 一句话总结

- 称作「横截面」，因为我们在**某个时点对所有股票做截面比较**
- 用「1月末因子 → 2月收益」，是为了保证因子作为**预测变量**，避免偷看未来

二、多期回测（time-series rolling test）

思路：

- 把单期检验扩展到多个时期，形成一个"时间序列"
- 每期都做一次横截面检验，得到一串 IC 或 分层收益
- 最终看**长期平均表现 + 稳定性**

常见做法：

1. **IC 时间序列**
    - 每个月计算一次因子 IC，得到一个时间序列
    - 看它的**均值（有效性）**和**标准差（稳定性）**

2. **分层回测时间序列**

- 每个月把股票分成 Q1~Q5 五组，分别计算收益
- 把所有月份累积起来，看长期 Q5 > Q1 吗？Q5-Q1 曲线是否长期向上？

3. **滚动统计（Rolling）**

- 比如用过去 36 个月作为一个"窗口"，每次向前滑动 6 个月
- 看在不同窗口下，因子表现是否稳健（是否总是 IC > 0，还是经常翻负）

三、为什么要多期回测？

1. **避免"过拟合"**

- 单期可能是"幸运的噪音"
- 多期检验能确认因子是长期有效，而不是一次性的

2. **适应市场风格切换**

- 牛市可能"动量因子"有效，熊市可能"价值因子"有效
- 多期检验能看到因子在不同市场环境下的表现

3. **评估稳定性**

- 单期因子 IC=0.3，可能很亮眼
- 但如果长期 IC 平均只有 0.02，且波动很大，这个因子不适合实盘

四、一个小例子

假设我们做了 12 个月的因子检验：

月份	单期IC
1月	0.25
2月	-0.05
3月	0.18
4月	0.30
5月	-0.10

- 如果你只看 1月，会觉得因子很强
- 但如果看 12 个月整体，发现平均 IC=0.08，波动很大 → 因子其实不稳健

这就是**单期 vs 多期**的区别。

五、完整代码实现（因子多期回测的三个方法）

现在用 60 支"股票"、48 个月的模拟数据做演示。因子是 factor_matrix（每月每股的因子值），未来月度收益由 0.08*factor + 噪声 生成（所以在模拟里因子是"有用的"）。然后做了三个检验并画图：

1. **IC 时间序列**— 每个月计算一次 Spearman IC（因子值 vs 当月的下一期收益），得到 IC 的时间序列并画图（Plot 1）
2. **分层回测时间序列（Q1~Q5）**— 每个月把股票按因子值分成 5 组（Q1 最低，Q5 最高），计算每组的当月（forward）平均收益，然后累计得到各组的累积收益曲线，并画出 Q5-Q1 多空曲线（Plot 2）
3. **滚动统计（window=36 个月，step=6 个月）**— 用过去 36 个月作为一个"窗口"、每隔 6 个月滚动一次，计算每个窗口的 IC 平均、IC 标准差、IR（IC_mean/IC_std）以及该窗口内 IC>0 的比例（Plot 3，和表格）

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from scipy.stats import spearmanr

plt.rcParams['font.sans-serif'] = ['PingFang HK']
plt.rcParams['axes.unicode_minus'] = False

# ---------------------
# Step 1: 模拟数据（60支股票，48个月）
# ---------------------
np.random.seed(42)
n_stocks = 60
n_months = 48

dates = pd.date_range("2020-01-01", periods=n_months, freq="M")
stocks = [f"S{i:03d}" for i in range(n_stocks)]

# 随机生成因子值
factor_matrix = np.random.randn(n_months, n_stocks)

# 生成收益：因子+噪声
returns_matrix = 0.08 * factor_matrix + 0.2 * np.random.randn(n_months, n_stocks)

# ---------------------
# Step 2: 计算每月 IC
# ---------------------
ic_series = []
for t in range(n_months):
    f = factor_matrix[t]
    r = returns_matrix[t]
    ic, _ = spearmanr(f, r)
    ic_series.append(ic)
ic_series = pd.Series(ic_series, index=dates)

# ---------------------
# Step 3: 分层回测（Q1~Q5）
# ---------------------
group_rets = {f"Q{i}": [] for i in range(1, 6)}
long_short = []
```

```python
for t in range(n_months):
    f = factor_matrix[t]
    r = returns_matrix[t]
    ranks = pd.qcut(f, 5, labels=False) + 1   # 分为5组（1=最低，5=最高）
    for i in range(1, 6):
        group_rets[f"Q{i}"].append(r[ranks == i].mean())
    long_short.append(group_rets["Q5"][-1] - group_rets["Q1"][-1])

group_ret_df = pd.DataFrame(group_rets, index=dates)
group_ret_df["Q5-Q1"] = long_short
group_cum_df = (1 + group_ret_df).cumprod()

# ---------------------
# Step 4: 滚动统计（36个月窗口，每次向前滑动6个月）
# ---------------------
def rolling_ic_stats(series, window=36, step=6):
    results = []
    for start in range(0, len(series) - window + 1, step):
        window_data = series.iloc[start:start+window]
        mean_ic = window_data.mean()
        std_ic = window_data.std()
        ir = mean_ic / std_ic if std_ic > 0 else np.nan
        pct_pos = (window_data > 0).mean()
        results.append({
            "start": window_data.index[0],
            "end": window_data.index[-1],
            "ic_mean": mean_ic,
            "ic_std": std_ic,
            "ir": ir,
            "pct_positive": pct_pos
        })
    return pd.DataFrame(results)

rolling_df = rolling_ic_stats(ic_series)

# ---------------------
# Step 5: 画图
# ---------------------
plt.figure(figsize=(10,4))
plt.plot(ic_series, marker="o")
plt.axhline(ic_series.mean(), color="red", linestyle="--", label="均值")
plt.axhline(0, color="black", linestyle="--")
plt.title("IC 时间序列")
plt.legend()
plt.show()

group_cum_df.plot(figsize=(10,5), title="分层回测累计收益")
plt.show()

plt.figure(figsize=(10,4))
plt.plot(rolling_df["end"], rolling_df["ic_mean"], marker="o", label="IC均值")
```

```
plt.plot(rolling_df["end"], rolling_df["ir"], marker="s", label="IR")
plt.axhline(0, color="black", linestyle="--")
plt.title("滚动窗口统计（36月窗口，步长6月）")
plt.legend()
plt.show()

print("滚动窗口统计：")
print(rolling_df)
```

图表解读

图 1 — IC 时间序列（每月 Spearman IC）

- **横轴**：时间（月）
- **纵轴**：IC 值（秩相关）
- **有两条参考线**：IC 的历史均值（虚线）和 0（黑色虚线）

如何解读：

- 如果 IC 大多数时间在 0 之上，说明因子倾向于正向预测未来收益（好）
- 看**波动性**：IC 很波动说明不稳定；IC 较稳定且均值明显大于 0，说明稳定的预测能力
- 例子（模拟结果）中：IC 整体在正区间，而且平均值比较明显（因为模拟里我让因子有 Signal）

图 2 — 分层回测累积收益（Q1~Q5）+ 多空（Q5-Q1）

- **每条曲线**是某一分组（Q1..Q5）的累积收益（按月复利，从 1 开始）
- **红线是 Q5-Q1（Long-Short）**

如何解读：

- 如果 Q5（顶层）长期高于 Q1（底层），且 Q5-Q1 向上（红线长期上升），说明因子在横截面上能够把"好股（高分）"和"坏股（低分）"区分开，长期能带来超额收益
- 观察曲线平滑性：如果多空曲线上涨但很抖动，说明因子虽有 Alpha 但不稳定或含高波动

图 3 — 滚动统计（窗口=36 月，步长=6 月）

- **每个点**是一个 36 个月窗口内的统计量（窗口结束时间为 X 轴）
- **显示滚动 IC_mean 和 IR（IC_mean / IC_std）**

如何解读：

- 通过滚动窗口你可以看到：在不同时间段（不同市场环境）因子是否持续有效
- 如果某些窗口 IC_mean 接近 0 或为负，说明在那段时间因子失效；如果大多数窗口 IC_mean > 0 且 IR 较高，说明稳定可靠
- 另外查看 pct_positive_ic（窗口内 IC 为正的比例）也很有帮助：如果该比率接近 1，说明在窗口中绝大多数月份 IC>0

实务中如何判定"可用"与否（经验规则）

- **IC（均值）**：
  - 非常好：> 0.05
  - 较好：$0.03 \sim 0.05$
  - 较弱：$0 \sim 0.03$
  - 无效/反向：≤ 0
- **IR（信息比）**$= \text{mean(IC)/std(IC)}$：
  - 强稳健：> 1.0
  - 还行：$0.5 \sim 1.0$
  - 不稳：< 0.5
- **pct_positive_ic（窗口内正 IC 的比例）**：
  - 越接近 1 越好；如果低于 0.5，要非常小心
- **分层回测（Q5-Q1）累积收益**：
  - 看长期是否持续上行，且抖动（波动）不过大
- **滚动窗口**：
  - 若在不同窗口下 IC_mean 都为正且 IR 可接受 → 因子稳定
  - 若某些窗口显著为负 → 因子受市场风格影响较大（需要进一步剖析：在哪些市场环境下有效）

为什么要做滚动（而不是只看全样本平均）

- **全样本平均会掩盖"时变性"**—— 一个因子可能在 2015–2018 有用，2019–2021 失效
- **滚动可以发现**因子在不同市场环境（牛市/熊市/震荡）下的表现差异，便于做风控与动态仓位调整（例如在窗口表现不好时缩小权重）
- **例如**：你可以设规则：当最近 36 个月 IR < 0.5 或 pct_positive_ic < 0.6 时，降低因子权重或停用因子

一些可操作建议（如何把这些检验流程放入你的研究流程）

1. **先做每月 IC & 分层回测（横截面）**，看单期是否有信号
2. **做时间序列 IC（12/24/36 月）并画图**，观察稳定性
3. **做 36 月滚动（步长 6）**来检验因子在不同时间段的稳健性
4. **记录 IR、pct_positive_ic、Q5-Q1 年化收益和波动**，把这些作为是否上线实盘的硬阈值
5. **若因子不稳**：尝试中性化（行业/市值）、对因子做平滑或合成多个相关因子（降低噪声），再重复检验

六、手算示例加深理解

下面我一步一步手算，用上面代码的相同数字 —— 便于你完全看懂每个公式与步骤。

1) 数据（原始）

我们有 5 只股票：A,B,C,D,E。 因子（factor）在 2023-01、2023-02、2023-03；对应的下一期收益（forward return）在 2023-02、2023-03、2023-04。

因子（month t）

- 2023-01: A=0.10, B=-0.20, C=0.50, D=0.30, E=-0.10
- 2023-02: A=0.20, B=0.00, C=0.40, D=0.10, E=-0.05
- 2023-03: A=0.15, B=-0.10, C=0.60, D=0.05, E=0.00

下一期收益（month t+1）

- 2023-02 (forward of 2023-01): A=0.05, B=-0.02, C=0.10, D=0.07, E=0.00
- 2023-03 (forward of 2023-02): A=0.03, B=-0.01, C=0.08, D=0.04, E=0.00
- 2023-04 (forward of 2023-03): A=0.02, B=-0.03, C=0.12, D=0.01, E=-0.01

2) 每期计算 Spearman IC（秩相关）并手工算一次（公式）

Spearman 相关公式（标准形式）：

$$\rho_s = 1 - \frac{6\sum d_i^2}{n(n^2-1)}$$

其中 $d_i =$（第 i 只股票的因子秩 - 它的收益秩），n=5。

期 1：用 2023-01 的因子去预测 2023-02 的收益

- **因子从小到大排序（秩1..5）**： B(-0.20)=1, E(-0.10)=2, A(0.10)=3, D(0.30)=4, C(0.50)=5
- **对应收益排序（2023-02）从小到大（秩）**： B(-0.02)=1, E(0.00)=2, A(0.05)=3, D(0.07)=4, C(0.10)=5
- **因子秩和收益秩完全一致**→ 每个 $d_i = 0$→ $\sum d_i^2 = 0 \Rightarrow \rho_s = 1 - 0 = 1.0$（完美正相关）

期 2：用 2023-02 的因子去预测 2023-03 的收益

- **因子（升序秩）**: E(-0.05)=1, B(0.00)=2, D(0.10)=3, A(0.20)=4, C(0.40)=5
- **收益（2023-03）升序秩**: B(-0.01)=1, E(0.00)=2, A(0.03)=3, D(0.04)=4, C(0.08)=5
- **逐只求 d = factor_rank - return_rank**：
  - A: factor_rank 4, return_rank 3 ⇒ d = 1 ⇒ d² = 1
  - B: 2 - 1 = 1 ⇒ d² = 1
  - C: 5 - 5 = 0 ⇒ d² = 0
  - D: 3 - 4 = -1 ⇒ d² = 1
  - E: 1 - 2 = -1 ⇒ d² = 1
- $\sum d_i^2 = 1+1+0+1+1 = 4$

- 代入公式（n=5）：$\rho_s = 1 - \frac{6 \times 4}{5(25-1)} = 1 - \frac{24}{120} = 1 - 0.2 = 0.8$

期 3：用 2023-03 的因子去预测 2023-04 的收益

- **因子升序秩**: B(-0.10)=1, E(0.00)=2, D(0.05)=3, A(0.15)=4, C(0.60)=5
- **收益升序秩**: B(-0.03)=1, E(-0.01)=2, D(0.01)=3, A(0.02)=4, C(0.12)=5
- **秩完全一致**⇒ 所有 $d_i = 0 \Rightarrow \rho_s = 1.0$

IC 时间序列 = [1.0, 0.8, 1.0]

- 平均 IC = (1 + 0.8 + 1) / 3 = 0.933333…
- 用总体标准差（population std，ddof=0）计算：
- 差值平方和 / 3 = (0.0666667² + (-0.1333333)² + 0.0666667²)/3 = 0.0088889
- std ≈ 0.0942809
- IR = mean / std ≈ 0.9333333 / 0.0942809 ≈ 9.9（非常高；说明在这个小例子里 IC 很稳定）

3) 分层分组（Q1~Q5）并计算每期组内平均收益、再做累积

说明：因为我们只有 5 支股票，分 5 组意味着每组正好 1 支 —— 便于手算；真实研究通常用更多股票，分 5 或 10 组。

期 1（用 2023-01 的因子把股票分组，查看 2023-02 的收益）：

- **因子排序（从小到大）**： B, E, A, D, C
- **所以**：
  - Q1（最低） = B → Q1 的收益 = B 在 2023-02 的收益 = -0.02
  - Q2 = E → 收益 = 0.00
  - Q3 = A → 收益 = 0.05
  - Q4 = D → 收益 = 0.07
  - Q5（最高） = C → 收益 = 0.10
- **多空（Q5-Q1）** = 0.10 - (-0.02) = 0.12

期 2（用 2023-02 因子分组，看 2023-03 收益）：

- **因子排序（升序）**: E, B, D, A, C
- **对应 2023-03 收益**：
  - Q1 = E → 0.00
  - Q2 = B → -0.01
  - Q3 = D → 0.04
  - Q4 = A → 0.03
  - Q5 = C → 0.08
- **Q5-Q1**= 0.08 - 0.00 = 0.08

期 3（用 2023-03 因子分组，看 2023-04 收益）：

- **因子排序**: B, E, D, A, C
- **对应 2023-04 收益**:
  - Q1 = B → -0.03
  - Q2 = E → -0.01
  - Q3 = D → 0.01
  - Q4 = A → 0.02
  - Q5 = C → 0.12
- **Q5-Q1**= 0.12 - (-0.03) = 0.15

把每个月的组收益累积（按月复利，从 1 开始）

以 Q5 为例（每月收益分别 0.10、0.08、0.12）:

- 累积因子 = (1 + 0.10) × (1 + 0.08) × (1 + 0.12) = 1.10 × 1.08 × 1.12 = ≈ 1.33056 → 累计 +33.056%

以 Q1 为例（每月 -0.02、-0.01、-0.03）:

- 累积 = 0.98 × 0.99 × 0.97 = ≈ 0.941094 → 累计 -5.8906%

多空（Q5-Q1）月度收益分别 0.12、0.08、0.15:

- 多空累积 = (1+0.12) × (1+0.08) × (1+0.15) = 1.12 × 1.08 × 1.15 = ≈ 1.39056 → 累计 +39.056%

4) 滚动窗口（window=3，step=1）说明并手算

- 我们的 IC 序列是：[1.0, 0.8, 1.0]（对应 3 个样本期），窗口长度 = 3，步长 = 1
- 只有一个窗口（cover 所有 3 期），统计结果就是:
- ic_mean = 0.933333…
- ic_std ≈ 0.0942809
- IR = ic_mean / ic_std ≈ 9.9
- pct_positive = proportion(IC > 0) = 3/3 = 1.0

为什么这样做? 滚动窗口的作用是：「把历史分成多个时间段，分别计算指标」，可以看到因子在不同时期（不同市场环境）是否一直有效。 在真实研究里我们通常用更长窗口（如 36 月）和较大步长（如每 3 或 6 个月滑动一次），以获得更稳健的统计结论；而本示例因为数据很少，用小窗口做演示。

5) 完整 Python 代码（和上面手算完全一致）

```
import pandas as pd
import numpy as np
from scipy.stats import spearmanr

# ---- 数据（固定示例，便于复现手算） ----
stocks = ["A","B","C","D","E"]

# 因子在 2023-01/02/03 三个时点的取值（我们用 month t 的因子去预测 t+1 的收益）
```

```
factor = pd.DataFrame({
    "2023-01": [0.10, -0.20, 0.50, 0.30, -0.10],
    "2023-02": [0.20,  0.00, 0.40, 0.10, -0.05],
    "2023-03": [0.15, -0.10, 0.60, 0.05,  0.00],
}, index=stocks).T

# 对应的"下一期"收益（即 2023-02/03/04 的收益）
forward_ret = pd.DataFrame({
    "2023-02": [0.05, -0.02, 0.10, 0.07, 0.00],
    "2023-03": [0.03, -0.01, 0.08, 0.04, 0.00],
    "2023-04": [0.02, -0.03, 0.12, 0.01, -0.01],
}, index=stocks).T

print("因子表（每列为股票）：\n", factor, "\n")
print("forward returns（下一期收益）:\n", forward_ret, "\n")

# ---- 1) 每期计算 Spearman IC ----
ic_list = []
periods = list(factor.index)  # 2023-01,2023-02,2023-03
for i, per in enumerate(periods):
    f = factor.loc[per].values
    r = forward_ret.iloc[i].values  # 对应的下一期收益行
    ic, _ = spearmanr(f, r)
    ic_list.append(ic)
ic_series = pd.Series(ic_list, index=["IC_for_2023-02", "IC_for_2023-03", "IC_for_2023-04"])
print("每期 Spearman IC:\n", ic_series, "\n")

# ---- 2) 分层回测 Q1..Q5（因为样本只有5只，5组意味着每组1支） ----
group_ret = {f"Q{i}": [] for i in range(1,6)}
long_short = []
for i, per in enumerate(periods):
    f = factor.loc[per]
    r = forward_ret.iloc[i]
    # 用 qcut 把因子分成5组（1..5），Q1 最低，Q5 最高
    groups = pd.qcut(f, 5, labels=False) + 1
    for q in range(1,6):
        mask = (groups == q)
        meanr = r[mask].mean()
        group_ret[f"Q{q}"].append(float(meanr))
    long_short.append(group_ret["Q5"][-1] - group_ret["Q1"][-1])

group_ret_df = pd.DataFrame(group_ret, index=["2023-02","2023-03","2023-04"])
group_ret_df["Q5-Q1"] = long_short
group_cum = (1 + group_ret_df).cumprod()
print("每期分组收益（Q1..Q5）以及 Q5-Q1：\n", group_ret_df, "\n")
print("分组累积收益（从1开始累乘）：\n", group_cum, "\n")

# ---- 3) 滚动统计：窗口=3（月），步长=1（月） ----
window = 3
ic_vals = ic_list
roll_stats = []
for start in range(0, len(ic_vals) - window + 1, 1):
```

```
    win = np.array(ic_vals[start:start+window])
    mean_ic = win.mean()
    std_ic = win.std(ddof=0)   # population std consistent with上文示例
    ir = mean_ic / std_ic if std_ic > 0 else np.nan
    pct_pos = (win > 0).mean()
    roll_stats.append({
        "start": 0 + start,
        "end": 0 + start + window - 1,
        "ic_mean": mean_ic,
        "ic_std": std_ic,
        "ir": ir,
        "pct_positive": pct_pos
    })
roll_df = pd.DataFrame(roll_stats)
print("滚动窗口统计 (window=3) :\n", roll_df.round(6), "\n")
```

输出结果如下：

```
因子表（每列为股票）:
                A    B    C     D     E
2023-01  0.10 -0.2  0.5  0.30 -0.10
2023-02  0.20  0.0  0.4  0.10 -0.05
2023-03  0.15 -0.1  0.6  0.05  0.00

forward returns（下一期收益）:
                A     B     C     D     E
2023-02  0.05 -0.02  0.10  0.07  0.00
2023-03  0.03 -0.01  0.08  0.04  0.00
2023-04  0.02 -0.03  0.12  0.01 -0.01

每期 Spearman IC:
 IC_for_2023-02    1.0
IC_for_2023-03    0.8
IC_for_2023-04    1.0
dtype: float64

每期分组收益（Q1..Q5）以及 Q5-Q1:
            Q1    Q2    Q3    Q4    Q5  Q5-Q1
2023-02 -0.02  0.00  0.05  0.07  0.10   0.12
2023-03  0.00 -0.01  0.04  0.03  0.08   0.08
2023-04 -0.03 -0.01  0.01  0.02  0.12   0.15

分组累积收益（从1开始累乘）:
               Q1      Q2       Q3        Q4       Q5    Q5-Q1
2023-02  0.9800  1.0000  1.05000  1.070000  1.10000  1.12000
2023-03  0.9800  0.9900  1.09200  1.102100  1.18800  1.20960
2023-04  0.9506  0.9801  1.10292  1.124142  1.33056  1.39104

滚动窗口统计（window=3）:
    start  end   ic_mean    ic_std        ir  pct_positive
0      0    2  0.933333  0.094281  9.899495           1.0
```

三、为什么要这样做（短答）

- **分组（Q1..Q5）**：把横截面的股票按因子排序，分组后比较高组和低组的后续回报，是检验因子是否能区分"好/坏股"的直接方式
- **累积 Q5 > Q1 / Q5-Q1 向上**：说明长期持有高因子组、做空低因子组能够赚钱（因子有经济意义，不是偶然）
- **IC 时间序列**：看每期 IC 是否稳定为正（只是正不够，还要稳定）
- **滚动窗口**：检查因子在不同历史段的稳健性（是否在所有窗口都>0 或 高 IR），防止某一段数据"污染"总体结论

四、建议（怎么把小样例扩展到真实研究）

1. **在真实池子里用更多股票（上百~上千）**，分组通常用 5 或 10 组
2. **IC 用 Spearman 更常见（稳健）**，也可同时看 Pearson
3. **滚动窗口常用 36 个月（3 年）窗口、步长 3 或 6 个月**；原因是要既观察长期稳定性，又不过度重叠造成冗余
4. **对于实盘，Q5-Q1 的交易要考虑交易成本/换手率**，并做含成本回测
5. **若某窗口表现很差，进一步研究该窗口的市场风格（牛/熊、行业主导等）**，确定因子在什么环境下有效

七、多空组合（Long-Short Portfolio）

1. 什么是多空组合?

- **多头（Long）**：买入（持有）因子值高的股票，比如「高 ROE」的股票
- **空头（Short）**：卖出（做空）因子值低的股票，比如「低 ROE」的股票
- **多空组合（Long-Short Portfolio）**：同时买高、卖低，用它的收益差来检验因子是否真的能带来**超额收益（Alpha）**

公式：

$$r_{long-short} = r_{Q5} - r_{Q1}$$

- Q5：因子值最高分组（通常代表因子看好的股票）
- Q1：因子值最低分组（因子最不看好的股票）

2. 为什么要做多空组合?

关键动机：

1. **剔除市场整体涨跌的影响**
   - 比如某个月市场整体涨 10%，即便因子完全无效，所有分组可能都涨了，IC、Q5 组看起来也不错
   - 但如果你做 Q5-Q1 差值，就能看出因子是否真能区分股票优劣
   - 如果因子有效 → Q5 组比 Q1 组表现更好 → $r_{long-short} > 0$
2. **直接反映因子能否产生 Alpha**

- 实盘中，我们关心的不是市场整体涨跌，而是「因子是否能带来超额收益」
- 多空收益序列 $r_{Q5} - r_{Q1}$正是这个超额

3. 一个具体的小例子（手算过程）

假设某个月有 5 只股票（A、B、C、D、E），我们计算了一个因子（比如 ROE）：

股票	ROE（因子值）	当月收益
A	20%	5%
B	15%	3%
C	10%	2%
D	5%	-1%
E	0%	-2%

分组（Q5~Q1，假设5只股直接划分）：

- Q5（高 ROE）：A, B （平均收益 = (5%+3%)/2 = 4%）
- Q1（低 ROE）：D, E （平均收益 = (-1% + -2%)/2 = -1.5%）

多空组合收益：

$$r_{long-short} = r_{Q5} - r_{Q1} = 4\% - (-1.5\%) = 5.5\%$$

解释：

- 如果你单纯买市场（随便买），整体可能是 1%（平均）
- 但如果你买高因子、卖低因子，就能额外多赚 5.5%
- 这就是因子带来的 Alpha 收益

4. 完整 Python 演示（用5只股票的例子）

```
import pandas as pd
import matplotlib.pyplot as plt

# ================================
# Step 1: 构造数据（3个月 × 5只股票）
# ================================
data = {
    "month": ["2023-01"]*5 + ["2023-02"]*5 + ["2023-03"]*5,
    "stock": ["A","B","C","D","E"]*3,
    "factor": [20,15,10,5,0,     # 1月因子
               18,12,8,6,1,      # 2月因子
               22,14,9,4,2],     # 3月因子
    "ret": [0.05,0.03,0.02,-0.01,-0.02,   # 1月收益
            0.04,0.02,0.01,-0.01,-0.03,   # 2月收益
```

```
            0.06,0.03,0.015,-0.005,-0.025] # 3月收益
}
df = pd.DataFrame(data)

# ================================
# Step 2: 按因子分组（Q5 高因子，Q1 低因子）
# ================================
results = []
for m, group in df.groupby("month"):
    # 按因子排序
    sorted_group = group.sort_values("factor", ascending=False)

    # 取前40%为 Q5，后40%为 Q1
    q5 = sorted_group.head(2)["ret"].mean()
    q1 = sorted_group.tail(2)["ret"].mean()

    long_short = q5 - q1
    results.append({"month": m, "Q5": q5, "Q1": q1, "long_short": long_short})

res_df = pd.DataFrame(results)

# ================================
# Step 3: 累积收益（画净值曲线）
# ================================
res_df["Q5_value"] = (1 + res_df["Q5"]).cumprod()
res_df["Q1_value"] = (1 + res_df["Q1"]).cumprod()
res_df["long_short_value"] = (1 + res_df["long_short"]).cumprod()

print(res_df)

# ================================
# Step 4: 画图
# ================================
plt.figure(figsize=(8,5))
plt.plot(res_df["month"], res_df["Q5_value"], label="Q5组合（高因子）")
plt.plot(res_df["month"], res_df["Q1_value"], label="Q1组合（低因子）")
plt.plot(res_df["month"], res_df["long_short_value"], label="多空组合 Q5-Q1", linestyle="--",
plt.xlabel("Month")
plt.ylabel("净值")
plt.title("因子分组与多空组合表现")
plt.legend()
plt.grid(True)
plt.show()
```

运行结果你会看到：

- **Q5曲线**：因子高分组的表现（长期往上）
- **Q1曲线**：因子低分组的表现（可能比较差）

- **多空曲线（Q5-Q1）**：如果长期向上，就说明因子真的能产生**超额收益 Alpha**

八、今日思考题

1. 如何判断一个因子的多期回测结果是否足够稳健，可以用于实盘？

核心判断标准：

1. **IC 稳定性指标**
   - IC 均值 > 0.03（较好）或 > 0.05（非常好）
   - IR（信息比）= IC均值/IC标准差 > 0.5（还行）或 > 1.0（强稳健）
   - pct_positive_ic > 0.6（窗口内正 IC 比例）
2. **分层回测表现**
   - Q5-Q1 多空组合年化收益 > 5%（考虑交易成本后）
   - Q5-Q1 曲线长期向上且波动不过大
   - 各分组收益单调性：Q5 > Q4 > Q3 > Q2 > Q1
3. **滚动窗口稳定性**
   - 大多数滚动窗口 IC_mean > 0
   - 不同市场环境下（牛市/熊市/震荡）表现相对稳定
   - 没有出现连续多个窗口显著为负的情况
4. **风险控制指标**
   - 最大回撤 < 20%（可接受）或 < 15%（较好）
   - 年化波动率在合理范围内
   - 换手率不过高（避免过度交易）

实操建议：

- 设置硬性阈值：IC均值 > 0.03 且 IR > 0.5 且 pct_positive > 0.6
- 如果指标不达标，考虑因子中性化、平滑处理或合成多个相关因子
- 在样本外数据上再次验证，确保泛化能力

2. 多空组合在实际交易中会遇到哪些问题？如何解决？

主要问题：

1. **做空限制**
   - 很多市场不允许做空或做空成本很高
   - 解决方案：只做多头，用 Q5-Q1 的收益差作为因子有效性指标，实际交易时只买入 Q5 组

2. **交易成本**

- 多空组合需要频繁调仓，交易成本较高
- 解决方案：降低调仓频率（如季度调仓）、选择流动性好的股票、考虑交易成本后的净收益

3. **资金约束**

- 做空需要保证金，资金利用率受限
- 解决方案：使用股指期货或ETF进行对冲，或者采用市场中性策略

4. **流动性风险**

- 某些股票流动性差，难以做空
- 解决方案：选择流动性好的股票，设置最小成交量阈值

实用建议：

- 先用多空组合验证因子有效性
- 实盘时根据资金规模和交易限制，选择合适的实现方式
- 考虑使用衍生品（期货、期权）进行对冲，降低交易成本

3. 如何设计一个完整的因子多期验证流程?

完整流程设计：

1. **数据准备阶段**

- 确保因子数据无未来信息泄露
- 处理缺失值和异常值
- 进行行业/市值中性化处理

2. **单期验证**

- 计算每期 IC（Pearson + Spearman）
- 进行分层回测（Q1-Q5）
- 分析因子分布和稳定性

3. **多期时间序列分析**

- 计算 IC 时间序列，观察趋势和波动
- 进行分层回测时间序列分析
- 计算累积收益曲线

4. **滚动窗口分析**

- 设置合适的窗口长度（如36个月）和步长（如6个月）
- 计算每个窗口的统计指标
- 分析不同市场环境下的表现

5. **样本外验证**

- 划分训练集和测试集
- 在训练集上优化参数
- 在测试集上验证效果

6. **风险分析**

- 计算最大回撤、波动率等风险指标
- 分析因子在不同市场环境下的表现
- 评估交易成本和流动性约束

7. **实盘准备**

- 设置风控阈值和仓位管理规则
- 设计动态调仓机制
- 建立监控和预警系统

关键成功因素：

- 严格避免未来信息泄露
- 充分考虑交易成本和市场约束
- 建立完善的风险管理体系
- 持续监控和优化策略表现

总结：多期分层回测是量化因子研究的重要环节，它帮助我们全面评估因子的有效性和稳定性。通过IC时间序列分析、分层回测、滚动统计等方法，我们能够识别真正有效的因子，避免被偶然性结果误导。多空组合的构建和评估，则为因子研究提供了直观的收益验证方法。记住，一个严谨的因子研究必须经过多期验证，确保在不同市场环境下都能保持稳定的表现。

量化交易入门指南 · 目录 ≡

<上一篇
量化交易入门指南：第22天 – Barra 风格因子简介

下一篇 >
量化交易入门指南：第24天 – 样本外检验（Out-of-Sample Test）

内容含AI生成图片，注意甄别
阅读 167

广告

Today



疯狂水世界

海上求生　重建水上乌托邦

即将推出

海上生存，经营建岛，轻松玩~

船长在拾荒

进入小游戏