量化交易入门指南：第24天 – 样本外检验（Out-of-Sample Test）

原创 逻辑与流 逻辑与流 2025年9月26日 00:03 北京 2人

本文深入探讨了量化策略的样本外检验方法，重点介绍了过拟合问题的核心概念和防范策略。通过详细分析样本内外数据分割、Walk-Forward Test实现，以及噪音与信号的区分方法，帮助读者建立完整的策略真实性验证体系，避免"记住历史噪音"的陷阱。

学习时间

- **理论学习**: 20分钟
- **代码实践**: 25分钟
- **思考总结**: 15分钟
- **总计**: 60分钟

一、什么是样本外检验?

到目前为止，我们做的整体回测、滚动回测，本质上都是在**样本内（In-Sample）**检验：

- 使用相同的一段历史数据
- 不断测试、优化参数
- 看因子/策略是否有效

但这样容易出现**过拟合（overfitting）**——你可能只是「记住了」历史数据的噪音。

因此必须要做**样本外回测（Out-of-Sample Test）**，才能检验策略的真实有效性。

1 什么是样本外检验?

- **样本内（In-Sample）**：用来开发和训练策略的历史数据
- **样本外（Out-of-Sample）**：完全没用过的新数据，用来验证策略是否还能奏效

举个例子：

- 2008–2018年数据 → 用来开发策略（样本内）
- 2019–2020年数据 → 用来检验策略（样本外）
- 如果样本外表现和样本内类似，说明策略**稳健**
- 如果样本外崩掉，说明可能是**过拟合**

二、样本外的常见方法

（1）固定分割

- 训练集：前80%时间（样本内）
- 测试集：后20%时间（样本外）

（2）滚动/扩展窗口（Walk-Forward Test）

- 每次用**过去T个月**做样本内训练
- 用**接下来的K个月**做样本外检验
- 不断向前滑动，重复这个过程

这就是类似机器学习里的「交叉验证」。

三、代码示例

样本内vs样本外的对比（简单切分70%/30%）：

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

plt.rcParams['font.sans-serif'] = ['PingFang HK']   # 或者 'Songti SC'、'STHeiti'
plt.rcParams['axes.unicode_minus'] = False

# 模拟月度收益（这里用随机数代替因子回测结果）
np.random.seed(42)
months = pd.date_range("2015-01-01", periods=60, freq="M")
net_ret = np.random.normal(0.01, 0.05, size=len(months))  # 策略月度收益
benchmark_ret = np.random.normal(0.008, 0.04, size=len(months))  # 基准

df = pd.DataFrame({"month": months, "net_ret": net_ret, "benchmark_ret": benchmark_ret})
df["net_value"] = (1 + df["net_ret"]).cumprod()
df["benchmark_value"] = (1 + df["benchmark_ret"]).cumprod()

# ----------------------------
# 样本内 / 样本外切分
# ----------------------------
split = int(len(df) * 0.7)
df["set"] = ["in-sample"]*split + ["out-of-sample"]*(len(df)-split)

# ----------------------------
# 画图
# ----------------------------
plt.figure(figsize=(10,6))
plt.plot(df["month"], df["net_value"], label="策略净值")
plt.plot(df["month"], df["benchmark_value"], label="基准净值")

# 用背景色区分 in-sample / out-of-sample
plt.axvspan(df["month"].iloc[0], df["month"].iloc[split-1], color="lightblue", alpha=0.3, la
```

```
plt.axvspan(df["month"].iloc[split], df["month"].iloc[-1], color="lightgreen", alpha=0.3, la

plt.title("样本内 vs 样本外 回测")
plt.legend()
plt.grid(True)
plt.show()
```

四、图像解读

- **蓝色背景**：样本内（策略开发）
- **绿色背景**：样本外（独立验证）
- 如果绿色区间里，策略还能稳定跑赢基准 → 策略更可信
- 如果绿色区间里，净值掉队 → 说明可能过拟合

五、今日思考题

1. 如果样本外表现大幅弱于样本内，你觉得该怎么处理？

说明策略可能**过拟合（overfitting）**了。也就是说，你的因子/参数只是在样本内数据里「碰巧有效」，但没有真正的经济逻辑支撑。

应对方法：

1. **回到因子逻辑**：检查因子是否有合理的经济学/财务学解释，还是纯粹「数据挖掘」
2. **降低模型复杂度**：如果用了太多参数/因子，可以尝试减少维度，避免过拟合
3. **扩展样本**：加入更多市场阶段的数据（牛市、熊市、震荡），看看因子是否稳健
4. **重新检验参数**：尝试不同的参数组合，看结果是否一致

核心：一个真正的Alpha因子，应该在样本外依然有效，而不是只在历史数据里有效。

2. 为什么Walk-Forward Test更接近实盘?

因为它模拟了「真实的交易流程」:

- 在**当下时点**，你只能用「过去的数据」去训练和调参
- 然后用「未来一小段时间」去验证
- 再往前走一步，继续重复

举个例子:

- 用2015–2018数据开发 → 在2019测试
- 然后往前滚：2016–2019数据开发 → 在2020测试
- …以此类推

这样就能避免「偷看未来数据」的错误，和实盘的操作逻辑几乎一致。

3. 你觉得在实际中，样本外检验占多少比例比较合适?

常见做法:

- 70%样本内 + 30%样本外（比较常见的分法）
- 80%样本内 + 20%样本外（如果数据量比较少）
- Walk-Forward Test：不按固定比例，而是每次滚动，比如「3年训练 + 1年验证」

原则:

- 样本内必须足够长，能覆盖不同市场行情（牛市/熊市/震荡）
- 样本外也要足够长，才能体现策略是否稳健

经验上:

- 金融时间序列一般要至少5–10年，才能比较稳妥
- 如果你的样本外只有几个月 → 不能算稳健检验

总结一句话:

- 样本内 → 用来「发现 & 设计」策略
- 样本外 → 用来「验证 & 淘汰」过拟合策略
- Walk-Forward → 最接近实盘，是最终检验手段

六、过拟合（Overfitting）详解

过拟合是量化里非常关键的概念。

1. 什么是过拟合?

过拟合就是：**模型在历史数据（样本内）表现很好，但在未来数据（样本外）表现很差。**

换句话说，它「学得太好」，把噪音当成了规律。

2. 举个例子

假设你在研究某个选股因子（比如PE值）：

- **正常情况**：你发现低PE股票大概率长期跑赢市场，但并不是每个月都赢
- **过拟合情况**：你把参数调得很细（比如只买PE在7.3～7.5的股票），在过去10年数据里能赚大钱。但是 → 这只是「数据巧合」，并没有经济学逻辑支撑。到了未来市场，可能完全失效

这就是过拟合。

3. 过拟合的典型表现

1. 样本内收益特别高，但样本外收益很差
2. 参数调得太细（比如0.01的间隔调参）
3. 模型复杂度太高（用了太多因子/太多神经网络层）
4. 没有经济逻辑支撑，纯靠数据挖掘

4. 如何避免过拟合?

1. **减少参数**：模型越简单，越不容易过拟合
2. **经济学逻辑优先**：因子必须有合理的经济解释，而不是数据巧合
3. **交叉验证**：用不同时间段/不同市场数据测试
4. **样本外检验**：把未来的数据留出来，看是否依然有效
5. **正则化（在机器学习里）**：限制模型复杂度，比如L1/L2正则

总结

- 过拟合就是"记住了历史噪音"，而不是学到了普适规律
- 在量化投资里，过拟合是**最危险的陷阱之一**
- 最有效的防御手段就是**样本外检验 + Walk-Forward Test**

七、噪音与信号的区分

过拟合的核心就是把"噪音"当成了信号。那我们就先搞清楚——什么是噪音?

1. 金融里的"信号"和"噪音"

- **信号（Signal）**：指有经济逻辑、可重复、长期有效的规律

- 比如：长期来看，低估值（PE低）的股票往往回报更高
- 高ROE的公司更容易跑赢市场

- **噪音（Noise）**：指短期的、随机的、不可重复的波动
  - 比如：某只股票因为CEO突然请病假而股价跌5%
  - 某天市场情绪极度亢奋，导致所有科技股暴涨
  - 某个因子在过去1年表现很好，但没有经济学依据

2. 举个例子

假设我们研究股价与天气的关系：

- 在2015~2020这6年，数据恰好显示「阴天时股价上涨概率更高」
- 如果你据此建立策略，这就是把"天气"这种噪音当成了信号

未来再看，就会发现根本没有任何规律，这就是过拟合。

3. 为什么金融市场"噪音"特别多？

因为市场价格每天都在受到成千上万因素的影响：

- 宏观经济数据（GDP、利率、通胀）
- 公司基本面（财报、分红、公告）
- 政策（监管、产业扶持）
- 突发事件（疫情、地缘政治、黑天鹅）
- 甚至纯粹的情绪和交易摩擦

这些短期因素会让价格剧烈波动，但很多并**不是长期规律**，因此就是"噪音"。

4. 怎么区分"噪音vs信号"？

- **看长期数据**：如果规律只在某2年成立，而在其他8年都不成立 → 很可能是噪音
- **看逻辑支撑**：是否有经济学/财务学解释？
- **看市场阶段**：如果规律只在某一类行情里成立（比如牛市），那它可能只是阶段性噪音

总结一句话

- **噪音**= 短期随机波动（不可复现、无逻辑）
- **信号**= 长期稳定规律（可复现、有逻辑）
- **过拟合**= 把噪音错当信号

八、Python实验：噪音被误判成信号

一个Python小实验，用随机数据造一个"假规律"，展示什么是噪音被误判成信号：

1. 随机生成100只股票的因子值（纯随机，无任何经济意义）
2. 随机生成下一期的收益率
3. 人为检查因子和收益的相关性（IC）

在纯噪音的情况下，有时也会"恰好"得到一个看似很强的相关性。

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from scipy.stats import spearmanr

plt.rcParams['font.sans-serif'] = ['PingFang HK']   # 或者 'Songti SC'、'STHeiti'
plt.rcParams['axes.unicode_minus'] = False

np.random.seed(42)

# Step 1: 随机生成100只股票的因子值（完全随机）
n_stocks = 100
factor = np.random.randn(n_stocks)   # 因子值，纯噪音
returns = np.random.randn(n_stocks)  # 下一期收益，同样纯噪音

df = pd.DataFrame({
    "因子值": factor,
    "下期收益": returns
})

# Step 2: 计算因子和收益的秩相关（Spearman IC）
ic, p_value = spearmanr(df["因子值"], df["下期收益"])

print(f"IC = {ic:.3f}, p-value = {p_value:.3f}")

# Step 3: 可视化
plt.scatter(df["因子值"], df["下期收益"], alpha=0.6)
plt.title(f"随机因子 vs 收益（IC={ic:.2f}）")
plt.xlabel("因子值（噪音）")
plt.ylabel("下期收益（噪音）")
plt.grid(True)
plt.show()
```

结果解释

- **理论上**：因子值和收益完全无关 → IC应该接近0
- **实际上**：可能会出现IC = 0.3、0.4甚至更高（只是统计上的"巧合"）
- **图上**：你会看到一些点"似乎有趋势"，但其实完全是噪音

这就是过拟合的风险——如果你只看这一期，就会误以为这个因子有效，但在下一期完全失效。

九、完整的防噪音/防过拟合策略清单

样本外检验（Out-of-sample Test）就是对付噪音和过拟合的核心方法。但它不是唯一的手段，避免过拟合我们通常要**多层防线**。我整理一份完整的防噪音/防过拟合策略清单，你能一眼看明白：

1. 样本外检验（Out-of-Sample Test）

- **核心思想**：不要只在"训练数据"上验证，而要在未来"没见过的数据"上检验
- **做法**：
  - 把数据分为训练集（In-sample）和测试集（Out-of-Sample）
  - 在训练集上找规律 → 在测试集上验证能否复现
- **意义**：如果一个规律只在样本内成立，到了样本外就失效 → 说明你抓到的只是"噪音"

2. 滚动回测（Rolling Window）

- 不要只看整体回测（全数据一次性），而是用**时间窗口滑动**的方式
- 例如：用2010~2015训练，2016测试 → 然后窗口前滚6个月，再训练 + 测试
- **好处**：能检查因子在不同市场阶段是否稳定
- 如果IC有时正、有时负，说明可能是噪音

3. 多期检验（长期累积验证）

- 单期（比如1个月）的好结果可能是噪音
- 必须看**长期**：
  - IC序列的均值（是否稳定正）
  - IC的标准差（是否波动太大）
  - 分组回测里Q5-Q1多空组合是否长期向上
- 这能过滤掉短期虚假的"因子有效性"

4. 经济学逻辑支撑

- 一个因子必须有**逻辑理由**，否则大概率是噪音
- 比如：
  - PE低 → 便宜 → 未来可能涨 ✔
  - 天气阴天 → 股票涨（典型噪音）

5. 降低模型复杂度

- 过拟合的根源之一是**模型太复杂**，硬是把训练数据的噪音都"记住"了
- **实际中**：
  - 不要用太多因子（几十上百个因子拼凑）
  - 控制模型自由度，比如用正则化（L1/L2）、简单打分法而不是复杂黑箱模型

6. 鲁棒性检验

- 换不同的数据、不同市场，看看结果是否还成立
- 换不同的参数（比如调仓频率、股票池大小），看因子是否仍然有效
- 如果稍微改一下参数，策略就失效 → 很可能过拟合

总结一句话

- 噪音不可避免，但我们要通过**样本外检验 + 滚动回测 + 长期验证 + 逻辑支撑**来确保我们抓到的是真正的**信号**，而不是"数据里的巧合"

总结：样本外检验是量化策略验证的核心环节，它帮助我们识别真正的Alpha因子，避免被历史噪音误导。通过建立完整的防过拟合体系，我们能够更准确地评估策略的真实表现，为实盘交易提供可靠的依据。记住，一个严谨的量化研究必须经过样本外检验的严格验证，才能确保策略的稳健性和可重复性。

量化交易入门指南 · 目录 ≡

〈上一篇

下一篇 〉

量化交易入门指南：第23天 – 多期分层回测 & 多空组合

量化交易入门指南：第25天 – 高频更新数据管理技巧（数据工程）

内容含AI生成图片，注意甄别

阅读 162

广告

Today



疯狂水世界

木筏求生，水世界生存为王

现已推出

抵御风暴鲨鱼，打造最强海上避难所！

水世界小杰

进入小游戏