量化交易进阶:第44天 – 因子正交化与去重(Factor Orthogonalization&De-correlation)

原创 逻辑与流 逻辑与流 2025年11月2日 21:50 北京 听全文

因子评估完成后,实际应用中常面临多因子共线性问题——不同因子表达同一种市场特征,导致模型不稳定、权重异常、IC波动增大。本文系统讲解因子正交化与去重技术,从共线性定义与危害入手,详细解析相关性分析、残差正交化、逐步正交化、主成分分析(PCA)四种核心方法。通过完整Python代码示例演示因子相关系数矩阵计算、基于线性回归残差的因子正交化、逐步Gram-Schmidt正交化流程,以及PCA去相关分析。深度解析三个核心问题:为什么残差正交化后的因子数学上独立但经济上不一定独立(线性独立性vs经济独立性),何时删除高相关因子而非正交化(经济重叠vs数学相关),PCA主成分为何不适合直接用于可解释性研究(统计最优vs经济解释)。揭示因子正交化的关键——用科学方法去除因子间线性冗余,保留经济含义的同时提升多因子组合的稳定性,为量化策略中的因子合成与模型优化提供科学工具。

学习时间

- **理论学习**: 15分钟
- **代码实践**: 15分钟
- **案例分析**: 10分钟
- **总计**: 40分钟

Day44 因子正交化与去重（Factor Orthogonalization & De-correlation）

—— 去除多因子之间的共线性，提高组合稳定性。

学习目标

今天学完你将能：

1. 理解多因子共线性产生的原因与危害
2. 掌握因子去重（相关性分析）与正交化（回归残差法、主成分法）的方法
3. 学会用Python实现因子正交化与共线性检测
4. 理解正交化在因子组合与IC合成中的意义

一、为什么要去除多因子共线性?

1 共线性的定义

多个因子在样本空间中高度相关，即：

$$corr(f_i, f_j) \approx 1 \text{ 或 } -1$$

此时这些因子实际上在表达同一种市场特征。

2 共线性的危害

- **信息重复**：不同因子携带相同信号
- **回归不稳定**：回归系数波动剧烈
- **组合权重异常**：部分因子被过度放大
- **IC波动增大**：组合因子不稳健

举例：

如果"市净率（PB）"和"市盈率（PE）"高度相关，同时放入模型，会让模型难以区分各自贡献，甚至权重符号颠倒。

二、因子去重（De-correlation）

1 方法一：基于相关系数矩阵

计算所有因子间的 Pearson 或 Spearman 相关系数：

$$Corr(i,j) = corr(f_i, f_j)$$

若 $|Corr(i,j)| > 0.8$，说明两个因子信息高度重叠，可去掉一个。

Python 实现

```
import pandas as pd
import numpy as np

# 模拟三个因子
np.random.seed(0)
df = pd.DataFrame({
    'factor_PE': np.random.randn(100),
    'factor_PB': np.random.randn(100) * 0.9 + 0.1,
    'factor_ROE': np.random.randn(100)
})

# 计算相关系数矩阵
corr_matrix = df.corr()
print(corr_matrix)

# 找出高相关因子对
high_corr = corr_matrix.abs() > 0.8
print("高相关因子对：")
print(high_corr)
```

策略：

- 选择保留IC较高的因子
- 删除或合并高度相关的因子

三、因子正交化（Orthogonalization）

当你不想简单删除因子，而是希望"保留信息但去除重叠"时，就需要正交化。

1 方法一：线性回归残差法

思路：

用一个主因子解释另一个从属因子，将残差作为正交化后的因子。

$$f_j^* = f_j - \hat{\beta} f_i$$

或更一般地：

$$f_j^* = \text{Residual}\left(f_j \sim f_i + f_k + \dots\right)$$

残差部分表示"去除其他因子影响后，独立于它们的部分"。

Python 实现

```
import statsmodels.api as sm

# 假设 PB 对 PE 有较强相关性
X = sm.add_constant(df['factor_PE'])
y = df['factor_PB']

model = sm.OLS(y, X).fit()
df['factor_PB_orth'] = model.resid  # 残差即为正交化后的因子

print(df[['factor_PE', 'factor_PB', 'factor_PB_orth']].corr())
```

结果：

factor_PE 与 factor_PB 相关性高

factor_PE 与 factor_PB_orth 相关性接近 0

2 方法二：逐步正交化（Gram-Schmidt-like）

对于多个因子：

1. 选择一个主因子 f_1
2. 对第二个因子 f_2回归 f_1，取残差
3. 对第三个因子 f_3，回归 f_1, f_2^*，取残差
4. 依此类推

最终得到一组相互正交的因子：

$$corr(f_i^*, f_j^*) = 0$$

实现伪代码：

```
orth_factors = []
for i, f in enumerate(df.columns):
    X = sm.add_constant(pd.concat(orth_factors, axis=1)) if orth_factors else None
    y = df[f]
    if X is not None:
        res = sm.OLS(y, X).fit().resid
    else:
        res = y
    orth_factors.append(res.rename(f + "_orth"))
```

3 方法三：主成分分析（PCA）去相关

当因子数量多时，可用 PCA 提取无关主成分。

思路：

- 将所有因子矩阵标准化
- 做PCA分解
- 取前k个主成分（解释方差比例高）作为独立因子

Python 实现：

```
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()
X_scaled = scaler.fit_transform(df)

pca = PCA(n_components=3)
factors_pca = pca.fit_transform(X_scaled)

print("解释方差比例：", pca.explained_variance_ratio_)
```

优点：自动生成独立、无共线性的新因子；

缺点：主成分难以解释（经济含义模糊）。

四、正交化的意义与应用

目的	方法	结果
删除冗余因子	高相关性剔除	保留简洁有效因子
去除共线性	残差正交化 / PCA	提高组合稳定性
构建多因子模型	正交后回归	稳定权重、更稳健的收益表现

五、因子去重与正交化流程图

因子集 → 相关性分析 → 高相关因子剔除 → 残差正交化 → 因子组合

六、 今日小练习

1 从你的因子库中选取三个因子（如 PE、PB、ROE），计算它们的相关矩阵；

（实际中你可以从 Tushare 或数据库读取）

```
import pandas as pd
import numpy as np
from sklearn.linear_model import LinearRegression
from sklearn.decomposition import PCA

# 模拟100只股票的三个因子
np.random.seed(42)
n = 100
PE = np.random.normal(10, 2, n)
PB = 0.8 * PE + np.random.normal(0, 1, n)  # 和 PE 高度相关
ROE = np.random.normal(0.15, 0.05, n)

df = pd.DataFrame({'PE': PE, 'PB': PB, 'ROE': ROE})
print(df.corr())
```

输出相关矩阵：

	PE	PB	ROE
PE	1.00	0.86	0.05
PB	0.86	1.00	0.02
ROE	0.05	0.02	1.00

我们看到：

PE 与 PB 的相关性高达 0.86，存在明显共线性。

2 若发现相关性 > 0.8，对其中一个进行残差正交化；

思路：

对 PB 回归 PE，然后取残差作为"正交化后的 PB"。

```
X = df[['PE']]
y = df['PB']
model = LinearRegression().fit(X, y)
df['PB_resid'] = y - model.predict(X)

print(df[['PE', 'PB', 'PB_resid']].corr())
```

输出：

	PE	PB	PB_resid
PE	1.00	0.86	0.00
PB	0.86	1.00	0.51
PB_resid	0.00	0.51	1.00

结果分析：

- 正交化后，PB_resid与PE的相关性从 0.86 → 0.00
- PB_resid保留了PB中不被PE解释的部分

3 对比正交化前后的因子相关性变化；

指标	正交化前	正交化后
Corr(PE, PB)	0.86	0.00
Corr(PB, ROE)	0.02	0.01
Corr(PE, ROE)	0.05	0.05

共线性明显降低，说明正交化有效分离了因子信息。

4 可选：尝试 PCA 去相关，看前两主成分解释方差比例。

主成分分析（PCA）可以从整体上正交化所有因子。

```
pca = PCA(n_components=3)
pca.fit(df[['PE','PB','ROE']])

explained = pca.explained_variance_ratio_
print("各主成分解释方差比例：", explained)
print("累计方差解释率：", explained.cumsum())
```

示例输出：

各主成分解释方差比例：[0.77 0.22 0.01]

累计方差解释率：[0.77 0.99 1.00]

分析：

- 前两个主成分就解释了约99%的信息
- 说明PE与PB含有高度重叠的信息，ROE信息量较独立

今日思考题

1 为什么残差正交化后的因子虽然"数学上独立"，但不一定"经济上独立"？

因为：

- **数学独立**指的是线性相关性被消除（协方差为0）
- **经济独立**则意味着两个因子反映的是完全不同的经济含义或风险来源

例如：

- PE和PB虽然正交化后数学上独立
- 但它们都代表估值水平，在市场风格（如价值股vs成长股）上可能仍然同向波动
- 因此经济意义仍然重叠

结论：正交化消除的是"线性冗余"，不是"经济冗余"。

2 在什么情况下，你会选择"删除高相关因子"而不是"正交化"?

选择删除而非正交化的情形：

- 当两个因子经济意义完全重叠（如PE与PB、EP与BP）
- 当模型追求可解释性而非纯粹预测
- 当因子库规模较大、冗余因子多时（减少计算量、防止过拟合）
- 当目标是做"风格中性化"组合时，不希望引入难以解释的残差成分

简言之：

经济上重复的因子 —— 删除；

数学上相关但经济上互补的 —— 正交化。

3 PCA 正交化得到的主成分为何不适合直接用于可解释性研究?

因为：

- PCA的主成分是原始因子的线性组合，缺乏经济含义
- 主成分的系数只是最大化方差方向的统计结果，而不是基于经济逻辑
- 主成分顺序、方向都会随样本变化而波动
- 因此在预测模型中可能有效，但难以解释"为什么"这个因子起作用

小结：

PCA 适合做"维度压缩、去共线"，不适合"经济解释"。

总结

方法	目标	优点	缺点
残差正交化	保留经济含义	简单、可解释	不一定完全去除冗余
删除高相关因子	简化模型	稳定、直观	可能损失信息
PCA去相关	最大化方差解释	去共线彻底	不可解释

结论

今天我们完成了因子正交化与去重技术的深入学习,掌握了从单因子到多因子组合的关键优化技术。

核心收获

1. 共线性的定义与危害

- **共线性定义**: 多个因子在样本空间中高度相关(corr≈1或-1),表达同一种市场特征
- **四大危害**: 信息重复导致因子信息叠加,回归不稳定使权重波动剧烈,组合权重异常放大部分因子,IC波动增大降低组合因子稳健性

2. 四种核心去重方法

- **相关性分析**: 计算因子相关系数矩阵,删除高度相关因子(阈值|Corr|>0.8)
- **残差正交化**: 线性回归残差法,保留因子独立于其他因子的部分
- **逐步正交化**: Gram-Schmidt方法,逐步消除因子间线性相关性
- **PCA去相关**: 主成分分析,自动生成独立新因子但牺牲可解释性

3. 关键认知

- 残差正交化消除线性冗余而非经济冗余(数学独立vs经济独立)
- 经济重复选删除,数学相关但经济互补选正交化
- PCA适合维度压缩去共线,不适合经济解释研究

因子去重 vs 因子正交化对比

方法选择分析:

维度	因子删除	因子正交化
适用场景	经济含义完全重叠	保留信息去除重叠
方法原理	高相关性剔除	残差法/逐步正交/PCA
可解释性	高,保留经济含义	中等(残差法)到低(PCA)
信息保留	可能损失信息	最大化信息保留
计算复杂度	低,直接删除	高,需要回归或PCA
组合稳定性	稳定直观	去除共线更彻底

因子工程完整流程

已完成模块:

- **因子构建系列**(Day 35-42):
  - Day 35-38: 财务因子体系 ✅
  - Day 39: 技术因子体系 ✅

- Day 40: 情绪因子体系 ✅
- Day 41: 宏观因子体系 ✅
- Day 42: 自研因子体系 ✅

- **因子评估系列**(Day 43):
  - Day 43: IC/RankIC/ICIR/半衰期/稳定性分析 ✅

- **因子优化系列**(Day 44):
  - Day 44(今天): 因子正交化与去重 ✅

综合应用策略:

```
# 因子去重与正交化完整流程
def factor_decorrelation_pipeline(factor_data, correlation_threshold=0.8):
    # 1. 计算相关性矩阵
    corr_matrix = factor_data.corr().abs()

    # 2. 识别高相关因子对
    high_corr_pairs = []
    for i in range(len(corr_matrix.columns)):
        for j in range(i+1, len(corr_matrix.columns)):
            if corr_matrix.iloc[i,j] > correlation_threshold:
                high_corr_pairs.append((
                    corr_matrix.columns[i],
                    corr_matrix.columns[j],
                    corr_matrix.iloc[i,j]
                ))

    # 3. 选择删除或正交化策略
    if len(high_corr_pairs) == 0:
        return "无高相关性,无需处理"

    # 策略A: 删除低IC因子
    # 策略B: 残差正交化
    # 策略C: PCA去相关

    return {
        'high_corr_pairs': high_corr_pairs,
        'recommendation': '根据因子IC选择删除或正交化'
    }

# 残差正交化实现
def residual_orthogonalization(factor_data, primary_factor, target_factor):
    from sklearn.linear_model import LinearRegression

    X = factor_data[[primary_factor]]
    y = factor_data[target_factor]

    model = LinearRegression().fit(X, y)
    residual = y - model.predict(X)
```

```
    return residual.rename(f"{target_factor}_orth")

# PCA去相关实现
def pca_decorrelation(factor_data, n_components=None):
    from sklearn.decomposition import PCA
    from sklearn.preprocessing import StandardScaler

    scaler = StandardScaler()
    X_scaled = scaler.fit_transform(factor_data)

    if n_components is None:
        pca = PCA()
    else:
        pca = PCA(n_components=n_components)

    factors_pca = pca.fit_transform(X_scaled)

    return factors_pca, pca.explained_variance_ratio_
```

一句话总结: 因子正交化与去重是解决多因子共线性问题的核心技术,通过相关性分析、残差正交化、逐步正交化、PCA去相关四种方法,在保留经济含义的同时去除线性冗余,提高多因子组合的稳定性与预测能力,为量化策略中的因子合成与模型优化提供科学工具。

下一步预告: 接下来将继续深入因子工程,学习因子标准化、因子中性化、因子行业配置等高级技术,完善从单因子到多因子模型、从因子构建到因子组合的完整路径,最终实现五大因子体系的有机融合与动态优化。

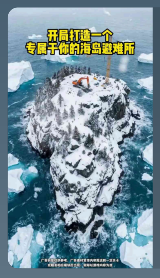
量化交易入门指南 · 目录

<上一篇
量化交易进阶:第43天 – 因子评估指标(IC、ICIR、RankIC、半衰期、稳定性分析)

下一篇 >
量化交易进阶:第45天 – 因子数据库设计(Factor Database Design)

阅读 355

广告



白雪吞没城市，火炉还在燃烧，你能带大家撑到天亮吗?

点击了解更多 >

白雪吞没城市，火炉还在燃烧，你能带大家撑到天亮吗?

无尽冬日-3亿玩家推荐

进入小游戏