量化交易进阶:第47天 – 因子研究复盘 自动生成因子表现报告(IC 曲线 + 分层收益)

原创 逻辑与流 逻辑与流 2025年11月8日 23:18 北京 听全文

摘要：聚焦IC曲线与分层收益两大指标,并通过Python脚本实现因子表现的全流程自动化复盘。

我们正式进入“量化研究员的报告自动化阶段”，这也是从“写代码做研究”到“构建研究体系”的关键一步。

学习目标

今天我们要实现两件事：

1. 理论部分：理解 IC 曲线、分层收益（Group Return） 如何反映因子有效性；
2. 实践部分：用 Python 自动生成一份因子表现报告，内容包括：
   - 因子每日 IC 曲线；
   - 因子多空组合收益曲线；
   - 各分层年化收益、信息比率表格。

一、理论讲解：IC 曲线与分层收益

1. 因子有效性度量的两种视角

指标	含义	适用场景
IC 曲线（Information Coefficient）	衡量因子预测的“方向是否正确”。IC 越高，说明因子越能预测未来收益。	因子选优
分层收益（Group Return）	衡量因子高低分组之间的实际收益差异。	因子实际收益能力

2. IC 曲线的经济含义

- 若因子能预测股票未来收益，那么“因子值高 → 未来收益高”，则 Spearman 相关系数（RankIC）应为正。
- IC > 0.05 通常认为因子有效；
- IC 稳定、波动小（ICIR 高） 更加可靠。

3. 分层收益法（Group Return Analysis）

流程如下：

1. 将所有股票按因子值排序；
2. 划分为 5 组（Q1–Q5）；
3. 分别计算每组未来一段时间（如 5 日、20 日）的平均收益；
4. Q5 - Q1 即为多空收益。

若 Q5 > Q1 且稳定上升，说明因子有效。

因子研究中"分层（分组）方法"的核心逻辑，这实际上是量化研究员每天都在操作的关键步骤。

我们来一步一步拆开讲清楚。

为什么要"排序 + 分组"

因子研究的目标，是想回答：

"高因子值的股票，未来是不是表现更好？"

要验证这个问题，就要：

- 先看每只股票的因子值（比如 PE、ROE、动量等）；
- 把股票从低到高（或从高到低）排序；
- 然后分成几层（分组），观察每层的平均收益。

这样我们就能直观地看到：

因子值高的那一组，未来收益是否真的高。

二、排序 + 分组的数学步骤

假设今天（t 日）有 100 只股票，我们计算了它们的某个因子（例如 ROE）：

股票	ROE（因子）
A	5.2
B	9.8
C	2.1
…	…
Z	15.3

Step 1：排序（Sort）

先按因子值从小到大排序（ascending），

如果这个因子是"值越大越好"，那我们从小到大；

如果是"越小越好"（比如 PE），则可以从大到小。

在 pandas 中可以这样写：

```
df = df.sort_values("factor")
```

Step 2：分组（Quantile 分层）

把排序后的股票均匀地分为 5 组，也就是每组 20 只股票（100 ÷ 5 = 20）。

这种分法叫分位数分组（Quantile Grouping），即按照因子分布的 20%、40%、60%、80%、100% 分割。

在 pandas 中可以这样写：

```
df["group"] = pd.qcut(df["factor"], 5, labels=False)
```

这行代码含义是：

group 值	含义
0	因子值最低的 20% 股票（Q1）
1	第二层（20%–40%）
2	第三层
3	第四层
4	因子值最高的 20% 股票（Q5）

Step 3：计算各组未来收益

例如计算每组股票的未来 5 日收益率平均值：

```
group_return = df.groupby("group")["future_ret"].mean()
```

结果可能是这样：

组别	平均未来收益
Q1（低因子组）	0.1%
Q2	0.2%
Q3	0.4%
Q4	0.7%
Q5（高因子组）	1.1%

Step 4：判断因子有效性

- 若收益从 Q1 → Q5 逐渐上升，说明因子值越高 → 未来收益越高，因子有效（正向因子）。
- 若收益从 Q1 → Q5 逐渐下降，说明因子值越高 → 未来收益越低，因子为反向因子（例如 PE）。
- 若没有规律，说明因子无效或噪声大。

三、完整示例（Python演示）

假设我们有 10 只股票的因子与未来收益：

```
import pandas as pd
import numpy as np

# 模拟数据
df = pd.DataFrame({
    "stock": [f"S{i}" for i in range(1,11)],
    "factor": [5.2, 3.1, 8.7, 6.0, 1.5, 9.8, 4.2, 7.3, 2.9, 5.9],
    "future_ret": np.random.randn(10)/100
})

# Step 1: 按因子从小到大排序
df = df.sort_values("factor")

# Step 2: 分为5组 (Q1–Q5)
df["group"] = pd.qcut(df["factor"], 5, labels=["Q1","Q2","Q3","Q4","Q5"])

# Step 3: 每组平均未来收益
group_ret = df.groupby("group")["future_ret"].mean()
print(group_ret)
```

输出类似：

group

Q1 -0.0032

Q2 0.0010

Q3 0.0025

Q4 0.0037

Q5 0.0075

Name: future_ret, dtype: float64

可以看到：收益随因子值上升而增加，说明这个因子预测能力较强。

四、拓展：不同的分组方法

方法	说明	适用场景
qcut 分位数分组	每组样本数量相等（最常用）	样本分布较均匀
cut 区间分组	每组因子区间相等，但样本数量不均	样本极端分布时
自定义分组	例如分为“高、中、低”三层	实盘组合划分

小结

步骤	操作	含义
排序	按因子值从低到高排序	模拟投资者按信号选股
分组	按分位数切分成 5 层	检验不同“强度”的股票表现
计算	每组未来收益	量化因子预测力
比较	Q5 – Q1	判断正向/反向有效性

五、数学与逻辑推导

1. IC（信息系数）定义

$$IC_t = corr(rank(factor_t), rank(return_{t+1}))$$

即：当天因子值与未来收益的秩相关系数。

2. 分层收益（Group Return）定义

$$R_i = \frac{1}{N_i} \sum_{j \in group_i} return_j$$

多空收益：

$$R_{long-short} = R_{top} - R_{bottom}$$

六、Python 实现：基于 Tushare 的因子表现报告

```
import tushare as ts

import pandas as pd

import numpy as np

import matplotlib.pyplot as plt

from scipy.stats import spearmanr
```

```
import warnings

warnings.filterwarnings("ignore")

plt.rcParams['font.sans-serif'] = ['PingFang HK']

plt.rcParams['axes.unicode_minus'] = False


# ====== Step 1. 初始化 tushare ======
ts.set_token("你的_tushare_token")
pro = ts.pro_api()

# ====== Step 2. 获取股票列表（沪深300） ======

universe_start = '20230101'

universe_end = '20240115'

hs300 = pro.index_weight(index_code='000300.SH', start_date=universe_start, end_date=univers

hs300 = hs300.drop_duplicates(subset=['con_code'])

stock_list = hs300['con_code'].unique().tolist()[:30]  # 取前30只股票示例

# ====== Step 3. 获取PE因子 & 收益率数据 ======

def get_factor_and_return(ts_code):
    # 获取财务因子：市盈率（PE）

    df_pe = pro.daily_basic(

        ts_code=ts_code,

        start_date=universe_start,

        end_date=universe_end,

        fields='trade_date,pe_ttm'

    )

    # 获取价格数据：计算未来1日收益

    df_price = pro.daily(

        ts_code=ts_code,

        start_date=universe_start,

        end_date=universe_end,

        fields='trade_date,close'

    )
```

```
    df = pd.merge(df_pe, df_price, on='trade_date', how='inner')
    df = df.sort_values('trade_date')
    df['factor'] = df['pe_ttm']
    df['future_ret'] = df['close'].pct_change().shift(-1)
    df['ts_code'] = ts_code
    df = df[['trade_date','ts_code','factor','future_ret']].dropna()
    if len(df) < 10:
        return pd.DataFrame(columns=['trade_date','ts_code','factor','future_ret'])
    return df
# 聚合所有股票
all_data = []
for code in stock_list:
    df = get_factor_and_return(code)
    if len(df) > 30:
        all_data.append(df)
if not all_data:
    raise ValueError("选定股票在指定区间内缺乏足够PE或价格数据。")
data = pd.concat(all_data, ignore_index=True)
data['trade_date'] = pd.to_datetime(data['trade_date'])
# ====== Step 4. 计算每日 RankIC ======
ic_list = []
dates = sorted(data['trade_date'].unique())
for date in dates:
    subset = data[data['trade_date'] == date]
    if subset['factor'].nunique() > 5:
        ic, _ = spearmanr(subset['factor'], subset['future_ret'], nan_policy='omit')
        ic_list.append({'date': date, 'IC': ic})
```

```
ic_df = pd.DataFrame(ic_list).dropna()

if ic_df.empty:

    raise ValueError("IC 序列为空，请检查因子或收益率数据是否有效。")

# ====== Step 5. 分层收益分析 ======

# 以最近一个交易日为例，进行分层

latest_date = data['trade_date'].max()

subset = data[data['trade_date'] == latest_date].dropna(subset=['factor','future_ret'])

if subset.empty or subset['factor'].nunique() < 2:

    raise ValueError("最新交易日可用数据不足，无法进行分层分析。")

subset['group'] = pd.qcut(subset['factor'], 5, labels=False, duplicates='drop')

group_ret = subset.groupby('group')['future_ret'].mean()

# ====== Step 6. 可视化报告 ======
# --- IC 曲线 ---

plt.figure(figsize=(10,4))

plt.plot(ic_df['date'], ic_df['IC'], label='IC 曲线')

plt.axhline(0, color='gray', linestyle='--')

plt.title("PE 因子每日 RankIC 曲线")

plt.xlabel("日期")

plt.ylabel("IC 值")

plt.legend()

plt.grid(True)

plt.show()

# --- 分层收益图 ---

plt.figure(figsize=(6,4))

group_ret.plot(kind='bar')

plt.title(f"{latest_date.date()} PE 因子分层未来收益")

plt.xlabel("分组（因子值由低到高）")
```

```
plt.ylabel("未来日均收益")

plt.grid(True)

plt.show()

# --- 多空收益 ---
long_short_ret = group_ret.iloc[-1] - group_ret.iloc[0]

print(f"多空组合日均收益: {long_short_ret:.4%}")

# --- IC 统计 ---

ic_mean = ic_df['IC'].mean()

ic_std = ic_df['IC'].std()

icir = ic_mean / ic_std

print(f"IC均值: {ic_mean:.4f}, IC标准差: {ic_std:.4f}, ICIR: {icir:.2f}")
```

选取沪深300成份股中一批样本...

流程大致是：

- 在指定时间区间获取沪深300成份股，限定在有完整数据的股票。
- 对每只股票抓取 daily_basic 里的 pe_ttm 和 daily 里的收盘价，合并后生成因子序列和次日收益。
- 对全样本按交易日截面跑 Spearman RankIC，观察因子值与未来收益的相关性。
- 选最新交易日做一次按因子值的五分位分层，看高低分组的平均收益差异、计算多空收益。
- 最后用曲线和柱状图把 IC 走势、分层收益可视化，并输出 IC 统计指标。

总结来说，它是在验证 “PE 因子能否为未来一天的收益提供信息”——属于量化选股里常见的因子测试/回测框架的一个简化版本。

七、输出说明

1. IC 曲线

反映了 PE 因子与未来收益的相关性随时间的变化。

若 IC 大部分为正且稳定（波动不大），说明 PE 能持续预测未来收益。IC 大多围绕 0 震荡，正值区间代表 PE 因子在这些日子里同未来收益正相关，负值日说明信号反向；曲线的起伏反映了因子在样本期内稳定性一般，偶尔出现极端值需关注数据完整性。

2. 分层收益柱状图

股票按 PE 值从低到高分为 5 组（Q1–Q5）。

通常情况下：

- Q1（低PE）表现更好 → 代表“价值因子”有效；
- Q5（高PE）表现差 → 市场高估股票短期表现较弱。

3. 多空组合收益

- 多空组合日均收益：-0.4728%
- IC均值：-0.0492, IC标准差：0.2760, ICIR：-0.18

Q1 – Q5 为多空组合收益，若为正 → 表示低估值买入、高估值卖出能赚到钱。

八、思考题（带参考答案）

1. 为什么使用 PE 因子时，低 PE 股票往往收益更高?

   因为 PE 越低，代表估值越便宜，具备“价值回归”效应。

2. 为什么 PE 因子在不同年份效果不同?

   市场风格切换（如价值 vs 成长），会导致估值因子的 IC 波动。

3. 如果 IC 曲线长期围绕 0 上下波动，说明什么?

   因子预测力不稳定，或存在滞后，需要改进计算逻辑或换周期。

九、小结

模块	内容	意义
因子	PE（真实财务因子）	衡量估值水平
IC 曲线	IC均值 + 稳定性	判断预测方向正确性
分层收益	多空组合验证	判断收益可实现性
ICIR	评估稳定性	因子好坏的重要指标

结论

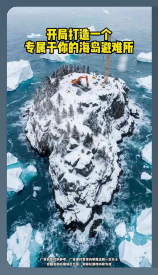
结论：PE 因子能否带来正向收益需结合 RankIC 和分层收益同步检验,自动化复盘让判断更直观。

量化交易进阶:第46天 – 数据存储工程化 因子每日更新脚本(pandas + SQLAlchemy)(进...

量化交易进阶:第48天 – 特征工程(因子标准化、缺失值填充、分箱、Winsorize 去极值)

阅读 131

广告



白雪吞没城市，火炉还在燃烧，你能带大家撑到天亮吗?

点击了解更多 ›

白雪吞没城市，火炉还在燃烧，你能带大家撑到天亮吗?

无尽冬日–3亿玩家推荐

进入小游戏