量化交易进阶:第48天 – 特征工程(因子标准化、缺失值填充、分箱、Winsorize 去极值)

原创 逻辑与流 逻辑与流 2025年11月9日 22:27 北京 听全文

摘要：回顾缺失值填充、去极值、标准化、分箱四大环节的理论要点，结合 Tushare 批量处理与贵州茅台实测案例演示完整流水线，并解释 Winsorize、行业中性化、分箱适用场景的实战取舍，帮助你搭建稳健可复用的因子预处理模版。

主题目标

在量化因子研究中，数据预处理（特征工程）是至关重要的一步。

即使一个好的因子，如果有极值、缺失、尺度不一致，也可能导致结果失真。

本节我们系统学习四大核心操作：

1 缺失值处理（Missing Value Imputation）
2 去极值（Winsorize）
3 标准化（Standardization）
4 分箱（Binning）

一、缺失值处理（Missing Value Imputation）

为什么有缺失值?

- 股票停牌、退市
- 财报未披露（例如 PE、ROE 暂时为空）
- 数据源异常

常见处理方法：

方法	说明	适用场景
删除样本	删除含缺失的行	数据量大、缺失较少
均值 / 中位数 / 众数填充	用全市场或行业均值代替	常用于基本面因子
前向 / 后向填充 (ffill, bfill)	用邻近日期数据填充	时序数据
分组填充	按行业或市值分组后填充	控制组间差异

```
df['pe'] = df['pe'].fillna(df['pe'].median())  # 用中位数填充
# 或者
df['pe'] = df.groupby('industry')['pe'].transform(lambda x: x.fillna(x.mean()))
```

二、去极值（Winsorize）

为什么要去极值?

极端值（outliers）会严重影响因子分布和相关性，例如：

- 财报错误：ROE = 9999%
- 暴涨暴跌导致 PE 异常

常见方法：

1 百分位截断法（Percentile Cut）

```
lower, upper = df['pe'].quantile(0.01), df['pe'].quantile(0.99)
df['pe'] = df['pe'].clip(lower, upper)
```

2 MAD（Median Absolute Deviation）法

```
median = df['pe'].median()
mad = (df['pe'] - median).abs().median()
df['pe'] = df['pe'].clip(median - 3*mad, median + 3*mad)
```

三、标准化（Standardization）

为什么标准化?

不同因子量纲不同：

- PE：几十到上百
- ROE：0~1
- 成交量：百万级

直接比较会导致权重失衡。

方法：

1 Z-score 标准化

```
df['pe_z'] = (df['pe'] - df['pe'].mean()) / df['pe'].std()
```

2 行业中性化标准化

```
df['pe_z'] = df.groupby('industry')['pe'].transform(
    lambda x: (x - x.mean()) / x.std()
)
```

3 Min-Max 归一化

```
df['pe_norm'] = (df['pe'] - df['pe'].min()) / (df['pe'].max() - df['pe'].min())
```

四、分箱（Binning）

为什么要分箱?

- 降低噪声，提高稳健性；
- 在分层回测中直接使用；
- 便于非线性关系分析。

方法:

```
# 等频分箱
df['pe_bin'] = pd.qcut(df['pe'], q=5, labels=False)

# 等距分箱
df['pe_bin'] = pd.cut(df['pe'], bins=5, labels=False)
```

等频（ qcut ）：每箱样本数相同
等距（ cut ）：每箱数值区间相同

五、综合示例：Tushare 因子预处理流程

```
import tushare as ts
import pandas as pd
import numpy as np

pro = ts.pro_api('你的Tushare Token')

# 1 获取某日股票基础数据
df = pro.daily_basic(ts_code='', trade_date='20250102',
                     fields='ts_code,pe,pb,roe')

# 2 缺失值填充
df['pe'] = df['pe'].fillna(df['pe'].median())
df['pb'] = df['pb'].fillna(df['pb'].median())
df['roe'] = df['roe'].fillna(df['roe'].median())

# 3 去极值
for col in ['pe','pb','roe']:
    lower, upper = df[col].quantile(0.01), df[col].quantile(0.99)
    df[col] = df[col].clip(lower, upper)
```

```
# 4 标准化
for col in ['pe','pb','roe']:
    df[col+'_z'] = (df[col] - df[col].mean()) / df[col].std()

# 5 分箱
df['pe_group'] = pd.qcut(df['pe'], 5, labels=False)

print(df.head())
```

今日小练习

1️⃣ 从 Tushare 获取近 1 年沪深 A 股的 PE、PB、ROE 数据；
2️⃣ 分别对这 3 个因子执行：缺失值填充 → 去极值 → 标准化；
3️⃣ 检查标准化后的均值与标准差是否接近 0、1；
4️⃣ 使用 `pd.qcut()` 将 PE 分为 5 桶，输出各桶均值。今日小练习这个你就用实际存在的某一只股票来完成，把这四道题目做了，用 Tushare。

练习答案（以贵州茅台为例）

```
import tushare as ts
import pandas as pd
import numpy as np
from datetime import datetime, timedelta

# ----------------------------
# 1️⃣ 初始化 & 获取近1年数据
# ----------------------------
pro = ts.pro_api('你的TushareToken')

end_date = datetime.now()
start_date = end_date - timedelta(days=365)
start_str = start_date.strftime('%Y%m%d')
end_str = end_date.strftime('%Y%m%d')

# 获取贵州茅台近1年的 daily_basic 数据
df = pro.daily_basic(
    ts_code='600519.SH',
    start_date=start_str,
    end_date=end_str,
    fields='ts_code,trade_date,pe,pb,roe'
)

df['trade_date'] = pd.to_datetime(df['trade_date'])
df = df.sort_values('trade_date')

print(\"原始数据样例：\")
print(df.head())
```

```
# ----------------------------
# 2️⃣ 缺失值填充 → 去极值 → 标准化
# ----------------------------

# 缺失值填充（用中位数）
for col in ['pe', 'pb', 'roe']:
    df[col] = df[col].fillna(df[col].median())

# 去极值（1%~99%分位）
for col in ['pe', 'pb', 'roe']:
    lower, upper = df[col].quantile(0.01), df[col].quantile(0.99)
    df[col] = df[col].clip(lower, upper)

# 标准化（Z-score）
for col in ['pe', 'pb', 'roe']:
    df[col + '_z'] = (df[col] - df[col].mean()) / df[col].std()

# ----------------------------
# 3️⃣ 检查标准化结果
# ----------------------------
stats = df[['pe_z', 'pb_z', 'roe_z']].agg(['mean', 'std'])
print(\"\\n标准化后各因子均值与标准差：\")
print(stats)

# ----------------------------
# 4️⃣ 使用 pd.qcut() 将 PE 分为 5 桶
# ----------------------------
df['pe_group'] = pd.qcut(df['pe'], q=5, labels=False)

group_mean = df.groupby('pe_group')['pe'].mean()
print(\"\\n按PE分为5桶后的均值：\")
print(group_mean)

# ----------------------------
# 输出最终样例
# ----------------------------
print(\"\\n最终处理后数据：\")
print(df[['trade_date', 'pe', 'pb', 'roe', 'pe_z', 'pb_z', 'roe_z', 'pe_group']].tail(10))
```

今日思考题详解（Day48：特征工程）

1 为什么 Winsorize 比直接删除极端值更稳健?

答案：

- Winsorize（缩尾处理）：将超过上下分位点的值替换为该分位点的数值；
- 删除极端值（Trim）：直接把这些样本剔除。

差异与影响：

方法	处理方式	样本数量	稳定性	适用场景
删除极端值	直接丢弃	减少	容易引入偏差	样本量大且异常点确实错误
Winsorize	替换为分位点	保留	更稳健	金融因子常用

举例说明：

假设我们要计算 PE 因子的均值：

- 一只“极端高估值”的股票 PE=500；
- 其他大部分股票 PE 在 10–50。

直接删除 PE=500 的股票，会改变样本数量与均值分布；而 Winsorize 只把它“压缩”到上分位（如 99% 分位=80），这样：

- 保留了样本；
- 降低了异常值的影响；
- 均值、标准差更稳健。

结论：

Winsorize 能平衡“数据完整性”与“稳健性”，在金融因子处理中几乎是默认选择。

2 若行业内数据分布差异极大（如银行 vs 科技），应如何处理标准化？

答案：分行业标准化（Industry Neutralization）

原因：

- 银行业的 PE 往往集中在 5–10；
- 科技行业可能在 30–80；
- 如果你全市场一起标准化：
  - 银行类股票的 PE 都会被判定为“低估”；
  - 科技股都变成“高估”；
  - 导致因子偏向行业，而不是个股特征。

正确做法：

```
df['pe_z'] = df.groupby('industry')['pe'].transform(lambda x: (x - x.mean()) / x.std())
```

结论：

行业中性化（Industry Neutralization）是因子标准化前的重要步骤，可以防止因子“偷带行业效应”，让信号更纯粹地反映个股差异。

3 为什么在机器学习模型（如 XGBoost）中，分箱反而可能降低性能?

答案：因为树模型本身已经能自动处理非线性与分段关系，无需再人为分箱。

原理分析：

- XGBoost / LightGBM 等模型基于树结构；
- 它们通过寻找最优分裂点（split point）来自动学习分段；
- 若我们人为先把连续变量分箱（例如 `qcut` 分成 5 桶）：
  - 会将连续信息离散化；
  - 造成信息损失；
  - 降低模型的拟合能力。

举例说明：

假设 PE 因子从 5 到 100 连续分布：

- 树模型本可找到“PE < 20”、“PE > 70”等精细边界；
- 但如果你提前分为 5 桶，只剩下 {0,1,2,3,4} 五个类别；
- 模型只能在桶之间分裂，无法捕捉更细的结构。

结论：

分箱适合线性模型或分层研究，不适合非线性模型（树、神经网络）。在 XGBoost 中应保持连续特征形式。

小结表

问题	核心答案
Winsorize 的优势	保留样本、降低异常点影响、稳健性更高
行业差异处理	分行业标准化（行业中性化）
分箱与树模型	分箱会损失信息，树模型已能自动分裂

结论

遵循“缺失值填充→去极值→标准化→分箱”的流程，可保持因子整洁性与稳定性，确保量化策略在不同场景下稳健发挥。

上一篇
量化交易进阶:第47天 – 因子研究复盘 自动生成因子表现报告(IC 曲线 + 分层收益)

下一篇
量化交易进阶:第49天 – LightGBM & CatBoost 用梯度提升模型预测收益与风险

阅读 103



开局一人一狗，无限探索资源，守护人类最后文明！

无尽冬日–3亿玩家力荐

进入小游戏