量化交易进阶:第51天 – 图神经网络（GNN）因子模型(进阶阶段·深度学习模块)

原创 逻辑与流 逻辑与流 2025年11月16日 21:54 北京 2人

本文系统讲解如何将图神经网络（GNN）用于量化因子增强：基于行业、相关性、产业链、共同持仓与ETF成分等关系构建“股票图”，通过图卷积/注意力/异质图Transformer等机制在股票之间传播与聚合信息，产出节点向量 h_i（Deep Factor）。对比行业图/相关性图/产业链图/Deep Factor 的适配场景与优劣，说明为何GNN应作为“因子工厂”（特征提取器）接入线性模型、CatBoost/XGBoost、LSTM/Transformer等预测器以完成排序、组合与风险管理，并给出稳健性评估与落地建议。

——“股票不是独立样本，而是一个图”

传统量化模型（LR / XGBoost / MLP / LSTM）都假设：

一只股票的特征独立于其他股票。

但真实市场完全不是这样：

- 同行业的股票会联动
- 产业链上下游会传导风险
- 大盘情绪会影响全市场
- 公募基金持仓结构会引起“抱团风格”
- ETF → 成分股之间有强相关

因此：

股票不是一条条孤立的数据，而是一个巨大的“股票关联图（Stock Graph）”。

图神经网络（GNN）正是为这种“样本之间有关联”的任务而生。

为什么 GNN 适合股票预测?

因为你的输入不再是：

单只股票

X_i = [PE_i, PB_i, ROE_i, Momentum_i, Volatility_i]

而是：

股票图 Graph G = (Nodes, Edges)

每个节点 = 一只股票

节点特征 = 股票因子

边特征 = 行业关系/产业链/相关性

GNN 的目标：

让每只股票吸收来自“邻居股票”的信息，

得到新的“图因子”（graph-enhanced factor）。

一、如何构建“股票图”？（核心）

GNN 的关键是如何定义股票之间的边（Edges）。

1）行业图（最常用、结构最清晰）

同一个行业 → 连边

细分行业越小，连边越强。

例如：

贵州茅台 —— 五粮液 —— 泸州老窖

恒瑞医药 —— 迈瑞医疗 —— 药明康德

这反映 行业风格联动。

2）相关性图（Correlation Graph）

计算 60 日收益率的相关系数：

corr(i, j) > 0.6 → 连边

优点：

- 自动反映市场资金抱团
- 随市场变化自动调整图结构

缺点：

- 容易过拟合
- 大盘下跌时强相关

3）产业链图（Supply Chain Graph）

从 WIND / Choice / 公司公告构建：

上游原料供应商 → 中游制造 → 下游零售

优点：

可以识别最真实的 传导链、盈利结构、逻辑关系。

4）基金持仓图（Co-holding Graph）

两只股票被相同基金大量持仓 → 连边

适合研究：

- 抱团股（A 股经常出现）
- 换手导致的连带下跌
- 板块流动性冲击

5）ETF 指数图

例如：

沪深300 → 成分股

中证白酒 → 白酒股

中证新能源 → 新能源股

能捕捉：

- 指数调仓
- ETF 申赎带来的流动性冲击

二、GNN 如何“增强因子”？

传统因子：

$X_i = [PE_i, PB_i, ROE_i, Momentum_i]$

GNN 聚合邻居信息后的因子：

$X'_i = GNN(i \mid neighbors)$

也就是：

你的因子 = 自己的特征 + 邻居股票的特征池化

在图卷积（GCN）里：

$X'_i = Mean(X_i, X_{neighbors})$

在 GAT（注意力图网络）里：

$X'_i = \Sigma\ attention(i, j) * X_j$

什么意思?

GNN 能判断哪些同类股票最重要，自动加权学习“股票风格联动特征”。

三、常用的 GNN 模型

模型	适合的场景
GCN（Graph Convolution）	数据稳定、关系明确，如行业图
GraphSAGE	大型图、增量学习、工业级模型
GAT（Graph Attention）	想识别最重要的邻居、行业内部差异大
HGT（异质图 Transformer）	产业链图（不同类型节点）
Temporal GNN / T-GAT	时序 + 图的联合建模

对于股票预测，一般最常用：

✔ GCN + LSTM

✔ GAT（图注意力）

✔ HGT（产业链）

四、图因子是怎么用在量化中的?

训练后的节点表示（node embedding）：

h_i = GNN(X_i, neighbors)

即：

h_i 就是“深度学习因子（Deep Factor）”。

然后你可以：

- 把 h_i 放入 LSTM 预测 5 日收益
- 把 h_i 放入 CatBoost
- 把 h_i 当作新的 alpha 因子做线性组合
- 计算 h_i 与收益的 RankIC
- 用 h_i 排序建组合

五、 四种图神经网络量化模型的区别（最清晰版本）

我用一句话概括：

（A）行业图：关系固定、最稳定 → 适合风格因子

（B）相关性图：关系动态、最敏感 → 适合捕捉资金抱团

（C）产业链图：因果结构、最真实 → 适合基本面逻辑

（D）Deep Factor：统一框架，把图 embedding 当新因子，用于任何模型

下面我详细展开。

（A）行业图 + GAT ——“行业内部的风格传导”

图结构怎么构造?

- 节点：股票
- 边：同一行业（或同一细分子行业）股票互相连边
- 边权重：GAT 自学注意力权重（股票对股票的影响力）

适用场景

✓ 研究 行业轮动、风格因子（价值/成长）

✓ 适合基本面投资，不经常变化

✓ 数据简单、稳定、无噪声

优点

- 图结构非常稳定（行业不会乱动）
- 特别适合 GAT 的注意力机制：

例如白酒行业中：

㊙ 茅台 → 五粮液 → 泸州老窖 影响力不同，GAT 会自动学习

缺点

- 行业内部差异大（比如医药有创新药、器械、原料药），图太粗糙
- 无法捕捉市场短期情绪

一句话总结

行业图适合做“稳定的、月级别风格 alpha”。

（B）相关性图 + GCN —— “资金抱团 + 市场风格”的动态捕捉

图结构怎么构造?

用 60 日滚动收益率相关性 构造图：

corr(i, j) > 0.5 → 连边

图结构 每天更新一次。

适合场景

✓ 捕捉 抱团股（比如 A 股白酒、新能源）

✓ 捕捉 风格切换（高股息 → TMT，周期 → 消费）

优点

- 市场在涨跌时，图会自动变化，能反映当下风格
- 无需行业分类即可找“市场真实关系”

缺点

- 噪声很大（相关性本来就不稳定）
- 图不稳定，容易过拟合
- 有时市场整体下跌 → 所有人都高度负相关

一句话总结

相关性图适合“情绪型 alpha”，捕捉 1–20 日收益的短期 signal。

（C）产业链图 + HGT —— “真实经济关系的因果图”

图结构怎么构造?

这是最专业、最高阶的图：

节点类型（heterogeneous graph，有多类型节点）：

- 上游材料
- 中游制造
- 下游品牌
- 经销商
- 终端零售
- 基金
- ETF
- 行业指数
- 公司本身

边类型（多关系）：

- “供应 → 制造”
- “制造 → 品牌”
- “基金 → 股票”
- “ETF → 成分股”
- “行业指数 → 股票”

适合场景

✓ 长期限逻辑（业绩、产业增长）

✓ 套利与高频预测（产业链传导）

✓ 传染效应（产业链利润压缩、供给紧张）

优点

- 结构真实（不是用相关性凑出来的）
- 异质图 Transformer（HGT）能识别不同关系的不同权重
- 解释性很强：能说清楚"为什么上涨"

缺点

- 构图难
- 数据来源依赖 Wind/Choice
- 工程复杂度高

一句话总结

产业链图代表"基本面因果 alpha"的最高级形态。

（D）Deep Factor —— 统一框架：任何图 → 输出 embedding 作为因子

无论你用：

- 行业图（A）
- 相关性图（B）
- 产业链图（C）

GNN 输出的节点 embedding：

h_i = GNN(X_i, neighbors)

都可以看成：

深度学习得到的新因子（Graph Factor 或 Deep Factor）

你可以把它：

- 加入你的因子库
- 与 PE/PB/ROE/Momentum 一起算 IC、信息比率
- 放入 XGBoost/CatBoost
- 放入你的多因子框架

优点

- 统一框架，高度灵活

- 你不需要直接用 GNN 预测收益
- 你把 GNN 当作“因子增强器”

缺点

- 需要管控过拟合
- 因子解释性较弱

一句话总结

Deep Factor 是“用图神经网络自动生成 alpha 因子”的通用方法。

四种方法的核心对比总结（看这个表就够了）

方法	图结构	模型	最适合的 alpha	周期	难度	解释性
（A）行业图 + GAT	固定行业关系	注意力图	行业风格、基本面因子	中期（月）	⭐	强
（B）相关性图 + GCN	随市场动态更新	图卷积	市场情绪、抱团效应	短期（1–20 日）	⭐⭐	中
（C）产业链图 + HGT	多节点、多关系	异质图 Transformer	基本面因果、产业传导	中长期	⭐⭐⭐⭐⭐	极强
（D）Deep Factor	任意图	任意 GNN	作为因子增强器	任意	⭐⭐~⭐⭐⭐⭐	弱~中

六、 着重讲解一下行业

行业图（Industry Graph）= 把 所有股票 按行业关系连起来的图

是一种 结构数据（Graph），用来表达股票之间“行业结构上的相似性”。

一句话解释

- 行业图 = 股票是节点 + 行业关系是边
- 并不是只分析白酒或医药，而是把所有行业的结构建成图，让模型自动从行业关系中学习特征。

行业图怎么构造?

1）股票作为节点

每个节点 = 一只股票

例如：贵州茅台、五粮液、海天味业、恒瑞医药……

2）边来自行业类别

最简单做法：

- 同一行业内 → 节点两两相连
- 不同行业之间 → 不连边

示例（极简）

白酒行业的图：

茅台 — 五粮液 — 泸州老窖 → 完全连通

医药行业的图：

恒瑞 — 科伦 — 复星医药 → 完全连通

两个行业彼此不连边。

这相当于告诉 GNN：

“同一行业的公司更相似，应该互相传播信息。”

“行业图” vs “选择一个行业分析”

概念	目的	数据范围
行业图（Industry Graph）	利用行业结构增强特征学习	所有股票
选择一个行业分析	行业研究 / 主题投资	白酒/医药等 少量股票

行业图是结构化建模，用于深度因子构建；

选择一个行业，是传统行业研究，不是图模型。

为什么行业图对 GNN 因子有用?

因为 GNN 擅长处理“关系”：

- 同行业公司会互相影响（供需 / 估值 / 情绪）
- 行业内收益率相关性更强
- 行业内基本面结构更接近

GNN 会让信息沿着边传播，比如：

茅台的收益/估值因素，会传播给五粮液、泸州老窖，帮助模型学习行业共性因子。

提问者关心的产业链图 vs 行业图?

对比一下：

图类型	节点	边含义	用法
行业图	股票	行业相同	行业结构
相关性图	股票	收益率高度相关	风险结构
产业链图	股票	上下游关系	供需结构
异质图（HGT）	股票/行业/供应商 等	多种关系	复杂信息融合

行业图是最简单、最稳定的图。

行业图能学到的 6 类核心信息

① 行业内的“共振”特征（行业 Beta）

同一行业的股票通常会一起涨跌——

- 情绪共振
- 需求周期共振
- 政策驱动
- 估值扩张或收缩

GNN 会自动从“行业内部的边”中学到：

“这些股票的特征应该相互影响。”

因此能提取出类似于行业 Beta 的深度因子。

例如：

茅台 ↑ → 五粮液、泸州老窖也会收到信息传递，从特征中学习到“行业共振”。

这类行业共振因子在回测中往往收益很高。

② 行业内的相对收益关系（alpha 因子）

行业内部股票互相比更有可比性。

比如白酒行业内部：

- 谁利润增长更快
- 谁估值更便宜
- 谁短期回调更大
- 谁库存压力更小

行业图帮助模型聚焦于同类竞争者的相对表现：

“你在行业里的相对位置好不好？”

这可以让模型对单只股票的 alpha 判断更准确。

③ 行业间的风格轮动关系（跨行业信息）

行业图不是孤岛，它包含 多个行业。

行业之间虽然不连边，但模型能通过每个行业内部的表现学到：

- 哪个行业进入景气周期
- 哪个行业在下行
- 哪些行业相互替代
- 哪些行业受宏观影响更强

这形成 风格轮动因子。

例如 GNN 会捕捉到：

新能源 ↓ 时 → 化工材料 ↑

地产 ↓ 时 → 银行/基建 ↑

这类"隐含行业关系"是传统因子很难捕捉的。

④ 行业内的异常点（outliers）

行业内部股票连接成团，因此 GNN 很擅长找异常行为。

如果行业都涨，只有你跌 → 模型学到你是弱势。

如果行业都跌，只有你涨 → 模型学到你是强势。

异常点是极好的交易信号。

⑤ 行业噪声过滤（denoising）

深度模型常过拟合，而行业图相当于正则化。

GNN 强制模型在同一行业的股票之间做平滑，使噪声减少。

例如：

某只小市值医药股涨停，但行业整体弱势 →

图结构会自动压低其权重，避免模型过度高估。

⑥ 行业中长期结构（结构型 Alpha）

行业图可捕捉：

- 行业龙头 vs 次龙头结构
- 高成长子行业 vs 老行业
- 高估值行业 vs 低估值行业
- 新能源产业链 vs 传统产业链的格局

这些结构会长期存在，而 GNN 能稳定学出来。

总结一句话

行业图不是为了“圈选一个行业研究”，

而是为了 让模型理解行业结构，并将这种结构用于预测收益率。

它可以从全市场中学到行业层面的：

✔ 行业共振

✔ 相对收益

✔ 风格轮动

✔ 异常点

✔ 噪声过滤

✔ 结构型 Alpha

这是单纯用表格数据无法做到的。

行业图（全 A 股）最后到底得到的是什么？

答案非常关键：

最终得到的是整个市场每只股票的 “深度学习因子”（Deep Factor） h_i。

简单说：

我们不是为了得到“白酒因子”或“医药因子”，

而是得到一个 ——

“包含行业 + 风险 + 同涨同跌结构 + 相关性” 的超级复合因子。

这个因子是一个向量（比如 32 维、64 维），叫 node embedding：

h_i ∈ R^32

每只股票一个。

但我只想研究白酒，为什么要全部股票？

因为：

- 白酒公司受到消费板块的影响
- 消费板块受到经济周期影响
- 周期股会影响金融股

- 金融股再反过来影响消费

行业之间是 网络结构，不是孤立的。

所以你必须把全市场放进去，才能“让信息流动”。

图神经网络就是模拟这种“信息传播”的：

白酒 → 食品饮料 → 消费 → 大盘 → 行业轮动 → 白酒

你的模型会自动学到：

- 板块联动
- 行业相似性
- 上下游关系（若加入供应链图）
- 风格暴露（价值/成长等）
- 系统性风险
- 行业轮动节奏

这些都是手工因子很难做的。

那最终得到的 h_i 是什么？给个更形象的解释？

你可以把它看成：

一个包含行业特征的“深度因子向量”。

比如：

h_贵州茅台 = [0.12, -0.33, 0.87, 1.2, -0.4, ...] # 64 维

h_恒瑞医药 = [0.92, -0.11, 0.01, 0.55, -0.72, ...]

h_招商银行 = [0.55, 1.2, -0.8, -0.1, 0.33, ...]

这些向量体现了：

内容	是否包含在 h_i 中	GNN 怎么学到的?
行业分类（GICS/申万）	✔	从行业网络结构传播过来
板块轮动方向	✔	图中邻居收益会影响节点
风格暴露（价值/成长）	✔	输入特征 + 图结构
产业链上下游关系	✔（如果加入产业链边）	来自异质图结构
高维非线性关系	✔	GAT attention
系统性风险	✔	信息在整张图上扩散
股票之间的相似性	✔	GNN embedding

所以 h_i 是一个“浓缩了全市场关系”的超级因子。

为什么说它是“超级因子”?

因为它包含：

① 行业因子（类似中证行业指数）

模型会自动学到哪些股票属于同一板块、联动性如何。

② 风格因子（价值/成长/大小盘）

从输入的 PE、PB、波动率等特征自动抽取出来。

③ alpha 因子（收益信号）

训练时你用未来收益/涨跌作为标签，模型会学习预测能力。

④ 风险因子（共性成分）

从图结构（行业、相关性）自然学到。

所以它比 PE、PB、ROE 这些浅层因子更强。

最终结果是什么?

最终你得到的不是一个“行业因子”，

也不是多个“每个行业一个因子”。

而是：

一个更强的 “Deep Factor”（每只股票一个向量）

然后你可以：

✔ 1. 直接用 h_i 来排序建多空组合

（像普通因子一样用）

✔ 2. 计算 h_i 与收益的 RankIC

（检验因子有效性）

✔ 3. 喂给 CatBoost/XGBoost

（提升预测准确率）

✔ 4. 喂给 LSTM/Transformer

（做时序因子）

✔ 5. 放入风险模型

（分解行业暴露、风格暴露）

🧭 你真正关心的核心概念

行业图不是为了研究行业，而是为了让深度模型"理解整个市场的结构"，从而生成更强的因子。

这就是为什么全 A 股都要放进去。

总结 Day 51：

GNN 是"股票之间的关系因子模型"。

它让模型从行业、风格、产业链、资金流等结构中学习更强的 alpha。

GNN 模型的最终目的是什么？

一句话：

GNN 的目的不是直接预测收益，而是"学习一个更强的因子（Deep Factor）"。

我们平时手工构造因子（PE、PB、ROE、动量、波动率、换手率……），这些都是"浅层因子"。

但市场真实关系是复杂 + 非线性 + 有网络结构的。

所以 GNN 会学习到一个新的"深度因子 h_i"，它包含：

- 公司的自身的特征（基本面、技术指标等）
- 邻居公司的行业关系
- 同产业链公司的上下游关系
- 市场相关性信息
- 行业板块风险因素
- 甚至"风格"信息（价值/成长/周期/医药/科技）

你可以把 h_i 理解成：

一个由网络信息 + 数据自动生成的"超级 Alpha 因子"

为什么还要把 GNN 产出的 h_i 再放到别的模型里？

因为 GNN 只负责"加工因子"，并不一定最擅长：

- 最终的收益预测（MLP/LSTM/CatBoost 更强）
- 横截面排序（线性模型更稳定）
- 风险控制（线性模型容易解释）
- 因子组合（传统方法更成熟）

所以通常流程是：

GNN 因子（Deep Factor）在量化中的常见使用方式

1.（最常见）把 h_i 当“因子”去做线性回归 / RankIC

h_i = GNN(X_i, neighbors)

RankIC(h_i, future_return)

GNN 负责学习：

- 行业关系
- 供应链
- 同涨同跌结构
- 风险暴露
- 信息传递

线性模型负责最终的：

- 排序
- 组合
- 风险分配

这是最稳健、机构最常用的方式。

2. 把 h_i 放进 CatBoost / XGBoost 预测未来收益

深度因子 h_i 作为特征：

pred = CatBoost(h_i, other_features)

CatBoost 善于处理：

- 树模型可解释性强
- 能挖掘非线性
- 不需要归一化
- 抗噪能力强

GNN 学表达能力，CatBoost 学预测能力，强强组合。

3. 把 h_i 放进 LSTM / Transformer（做时序）

使用过去60天的 h_i：

[h_i(t-60) … h_i(t)] → LSTM → 预测未来收益

这是像深度对冲基金（Citadel / Two Sigma）常用的做法。

GNN 捕捉横截面结构，LSTM 捕捉时间结构。

4. 直接用 h_i 排序做多空组合

这是最直接的：

分5组：Q1..Q5

Q5-Q1 = 多空收益

如果有效：

- h_i 越高 → 未来越涨
- h_i 越低 → 未来越跌

把 h_i 当成超强的"复合因子"。

那么 GNN 的位置到底在哪里？

不是：

预测模型本身。

而是：

因子加工 & 表达学习（Representation Learning） 的关键步骤。

就像 CV（计算机视觉）里：

- CNN 负责提特征（feature extractor）
- 分类器/检测器负责输出结果

在量化里：

- GNN = 特征提取器（Feature Extractor）
- CatBoost/LSTM/Linear = 预测器（Predictor）

你可以理解为：

原始特征 X →（GNN）→ Deep Factor h_i →（ML模型）→ Predict

（类比）为什么要这样设计？

类比：你看股票 K 线

只是 K 线 → 信息少

加一堆技术指标 → 信息丰富

再用行业/关系 → 信息更丰富

GNN 就像是：

自动学习"隐藏的信息"，比如：

- 哪些股票会一起涨？
- 哪些公司供应链联系紧密？

- 哪些板块关系强?

这些都是普通因子算不出来的。

最终总结（你一定要记住）

GNN 的最终目的：生成更强的因子（Deep Factor）。

它不会替代 CatBoost、LSTM，而是：

用图结构增强因子

→ 得到更强的 h_i

→ 再交给预测模型

GNN 是"因子工厂"，

CatBoost/线性模型/LSTM 才是"预测器"。

结论

- **定位**：GNN 是因子增强器与特征提取器，不直接取代预测器。
- **方法**：通过行业/相关性/产业链等图结构，让信息在股票间传播，形成更具解释力和预测力的 Deep Factor `h_i` 。
- **落地**：将 `h_i` 接入线性模型、CatBoost/XGBoost、LSTM/Transformer 等，完成排序、组合与风险管理。
- **实践建议**：先从稳定的行业图 + GAT/GCN 入手，逐步引入相关性图与产业链异质图（HGT），并严格做过拟合与稳健性检验（RankIC、分组回测、时变检验）。

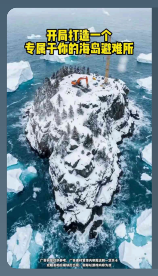
量化交易入门指南 · 目录 ≡

< 上一篇
量化交易进阶:第50天 – 深度学习因子模型 (Deep Factor Model)

下一篇 >
量化交易进阶:第52天 – 因子重要性与解释性 (Explainable ML for Quant)（进阶阶段·...

阅读 132

广告



白雪吞没城市，火炉还在燃烧，你能带大家撑到天亮吗?

点击了解更多 ›

白雪吞没城市，火炉还在燃烧，你能带大家撑到天亮吗?

无尽冬日-3亿玩家推荐

进入小游戏